



**CS450
CLOUD COMPUTING**

PROJEKTNI ZADATAK:

Unapređenje korisničko/informativnog sistema podrške kompanije Yettel d.o.o. Srbija implementacijom serverless AI Chatbot asistenta na AWS Cloud platformi

STUDENT:

Veljko Rakić, 5813
veljko.rakic.5813@metropolitan.ac.rs
U Beogradu, 07.06.2026

SADRŽAJ:

1	Uvod	5
2	Opšti podaci o poslovnom sistemu	5
2.1	Profil kompanije i pozicija na tržištu	5
2.2	Pregled usluga i delatnosti	6
2.3	Održivo poslovanje i ekološka svest	6
3	Analiza postojećeg informacionog sistema organizacije	7
3.1	Specifikacija softvera	7
3.2	Računarska i hardverska oprema	8
3.3	Komunikaciona infrastruktura i povezivanje sa internetom	9
3.4	Šema postojećeg informacionog sistema	10
3.4.1	Zona 1: Spoljno okruženje i korisnički komunikacioni kanal	11
3.4.2	Zona 2: Bezbedonosni perimetar i granica mreže	12
3.4.3	Zona 3: Korporativna mrežna infrastruktura	13
3.4.4	Zona 4: Lokalni on-premise data centar	14
3.4.5	Zona 5: Kontakt centar i krajnje tačke	15
3.5	Problemi i uska grla postojećeg informacionog sistema	16
4	Uporedni pregled tehnologija	17
4.1	Cloud Computing naspram on-premise infrastrukture	17
4.2	Analiza i selekcija Cloud provajdera za implementaciju	17
4.3	Arhitekture obrade prirodnog jezika: Opšti NLP naspram RAG sistema	18
4.3.1	Ograničenja opšteg Natural Language Processing (NLP)	18
4.3.2	Prednosti Retrieval-Augmented Generation (RAG) arhitekture	19
4.3.3	Generativni AI i modeli za ugrađivanje (Amazon Bedrock, Claude i Titan)	19
4.4	Uporedni pregled sistema za skladištenje i vektorsku pretragu	20
4.4.1	Vektorske baze podataka: OpenSearch Serverless naspram Amazon S3 Vectors	20
4.4.2	Logovanje konverzacija: Relacione naspram NoSQL baza podataka (Amazon DynamoDB)	21
4.5	Sistemi za Serverless izvršavanje i upravljanje API zahtevima	21
4.5.1	Tradicionalno hostovanje aplikacija naspram FaaS (Function-as-a-Service) modela	21
4.5.2	Upravljanje saobraćajem pomoću API Gateway-a	22
4.6	Hosting prezentacionog sloja i analitika	22
4.6.1	Statički hosting (Amazon S3): Tradicionalni veb-serveri naspram Object Storage hostinga	22

4.6.2	Infrastrukturni nadzor (Amazon CloudWatch).....	22
5	Predlog rešenja za unapređenje poslovnog sistema	23
5.1	Konceptualni dizajn i funkcionalni model predloženog rešenja.....	23
5.2	Arhitektura predloženog Cloud rešenja	24
5.3	Obim unapređenja i uticaj na poslovni sistem	25
5.3.1	Hibridno unapređenje sistema.....	26
5.3.2	Potpuna automatizacija	26
6	Implementacija rešenja za unapređenje poslovnog sistema	27
6.1	Inicijalizacija Cloud okruženja i kontrola pristupa	27
6.2	Konfiguracija sistema za perzistenciju podataka.....	30
6.3	Implementacija kognitivnog RAG sloja	32
6.4	Razvoj pozadinske logike i usmeravanje saobraćaja	34
6.5	Razvoj i distribucija prezentacionog sloja.....	37
6.6	Implementacija analitičkog modela	40
6.7	Nadzor infrastrukture	42
7	Analiza i prikaz postignutih rezultata.....	43
7.1	Inicijalno testiranje i analiza kognitivnog sloja	43
7.2	Analiza sistema za logovanje i menadžment analitiku	47
7.2.1	Preciznost detekcije i upisa u bazu.....	47
7.2.2	Prikaz analitičkog modula.....	48
7.3	Tehnička verifikacija i performanse sistema	48
7.3.1	Analiza CloudWatch metrika i stabilnosti infrastrukture	49
7.3.2	Vreme odziva	49
7.4	Komparativni pregled i operativni troškovi	50
7.4.1	Rešavanje operativnih uskih grla i uloga Tier 1 podrške	50
7.4.2	Komparativni prikaz on-premise naspram AWS Cloud rešenja	51
7.4.3	Projekcija troškova za realnu produkciju bazu korisnika	51
8	Zaključak.....	53
9	Literatura.....	54

SPISAK SLIKA:

Slika 1: Celokupna šema arhitekture	10
Slika 2: Prikaz komponente spoljnog okruženja i korisničkih kanala (Zona 1).....	11
Slika 3: Arhitektura bezbednosnog perimetra i demilitarizovane zone (Zona 2)	12
Slika 4: Struktura korporativne mrežne infrastrukture i rutiranja (Zona 3).....	13
Slika 5: Infrastruktura lokalnog on-premise data centra (Zona 4)	14
Slika 6: Krajnje tačke kontakt centra i operativni interfejsi agenata (Zona 5)	15
Slika 7: Krajnje tačke kontakt centra i operativni interfejsi remote agenata (Zona 5)	15
Slika 8: Šema arhitekture Cloud serverless AI chatbot sistema.	24
Slika 9: AWS okruženje konzole.	27
Slika 10: Prikaz modela Titan Text Embeddings V2 i Claude Opus 4.6 u katalogu modela	28
Slika 11: Kreirane korisničke role.	29
Slika 12: YettelChatbotLambdaRole permisije.	29
Slika 13: Predefinisana AWS permisija za YettelChatbotAPIGatewayRole.	29
Slika 14: Prikaz S3 bucket-a yettel-chatbot-data sa otpremljenim tekstualnim dokumentima Yettel baze znanja.	30
Slika 15: Prikaz S3 bucket-a yettel-chatbot-fronted sa otpremljenim fajlovima za klijentsku aplikaciju.	31
Slika 16: Prikaz tabela unutar DynamoDB.....	31
Slika 17: Prikaz YettelKnowledgeBase baze znanja u Amazon Bedrock-u.	32
Slika 18: Urađeni test u Test knowledge base servisu.	33
Slika 19: Primer Yettel 100 tarife u sačuvani tekstualnim fajlovima koji se nalaze u bazi znanja.	33
Slika 20: Prikaz koda YettelChatbotFunction funkcije.	35
Slika 21: Prikaz koda YettelChatbotFunction funkcije.	35
Slika 22: Prikaz koda YettelChatbotFunction funkcije.	36
Slika 23: Prikaz koda YettelChatbotFunction funkcije.	36
Slika 24: POST metode za rutu /chat unutar Amazon API Gateway.	37
Slika 25: Primer koda chatbot.js.....	38
Slika 26: Početna stranica statičkog sajta sa implementiranim AI Chatbot widget-om.	39
Slika 27: Otvoreni čit nakon klika na lebdeći widget.	39
Slika 28: Primer koda YettelAnalyticsFunction funkcije.....	41
Slika 29: Prikaz Yettel administratorske stranice sa analitikom podataka.	41
Slika 30: Dashboard YettelChatbotDashboard za nadzor funkcija.	42
Slika 31: Pitanja i odgovori.	44
Slika 32: Pitanja i odgovori drugi deo.	44
Slika 33: Pitanja i odgovori treći deo.....	45
Slika 34: Informacije sa sajta Yettel-a o paketu Yettel 100.....	45
Slika 35: FAQ o 5G.	46
Slika 36: DynamoDB tabela sa item-ima inicijalnih test pitanja i njihovim atributima.	47
Slika 37: Novi prikaz Yettel administratorske stranice sa analitikom podataka.	48
Slika 38: Prikaz Chatbot Function grafa metrika.	49
Slika 39: Prikaz Analytics Function grafa metrika.	50
Slika 40: Komparativna tabela.	51
Slika 41: Troškovi za implementaciju rešenja.	53

1 UVOD

Poslovno okruženje u visoko-konkurentnom sektoru telekomunikacija, zahteva od kompanija fleksibilnost i neprekidnu dostupnost usluga korisničke podrške i informacija. Problem mobilne kompanije Yettel d.o.o Srbija je to što se svakodnevno suočava sa velikim brojem korisničkih pitanja koja se odnose na njihove tarife, usluge, reklamacije, uređaje i opšte informacije. Uprkos visokom kvalitetu usluga, Yettel-ov trenutni poslovni sistem rešavanja ovog problema se prvenstveno zasniva na tradicionalnim call centrima i e-mail komunikaciji [1]. Ovi modeli interakcije sami po sebi nose nekoliko problema kao što su: dostupnost samo u radnom vremenu, preopterećenje korisničkih agenata u periodima visokog saobraćaja, a pritom zahtevaju i znatno visoke operativne troškove održavanja.

Cilj ovog projektnog zadatka je detaljna analiza modela korisničke podrške i dostupnost informacija kompanije Yettel Srbija i predlog naprednijeg tehnološkog rešenja u vidu uvođenja inteligentnog chatbot-a zasnovanog na Cloud tehnologijama i specifičnim korisničkim podacima organizacije. Kao glavno rešenje navedenog problema, u radu će biti projektovana arhitektura chatbot-a koji koristi koncepte generativne veštačke inteligencije i RAG (Retrieval-Augmented Generation) arhitekture.

Primarni cilj jeste automatsko razumevanje i odgovaranje na najčešća korisnička pitanja u realnom vremenu, na prirodnom srpskom jeziku, prevazilazeći tako ljudska ograničenja klasičnih call centara. RAG arhitektura omogućava da chatbot odgovore bazira isključivo na zvaničnim i pouzdanim dokumentima kompanije čime se eliminiše rizik od netačnih informacija [2]. A da bi se uspešno rešio problem zagušenja sistema usled velikog broja istovremenih upita korisnika, dizajnirani sistem treba da obuhvati serverless backend arhitekturu koja se automatski i samostalno skalira ukoliko nastupi period povećanog opterećenja [3]. Pored komponente za direktnu interakciju sa klijentima, sistem treba da obuhvati i cloud bazu podataka namenjenu isključivo za logovanje i bezbedno čuvanje obavljenih konverzacija. Ovi podaci služe kao osnova za analitički modul koji pruža jasan uvid u najčešće teme i probleme korisnika, omogućavajući kompaniji bolje delovanje na tržištu.

2 OPŠTI PODACI O POSLOVNOM SISTEMU

2.1 PROFIL KOMPANIJE I POZICIJA NA TRŽIŠTU

Poslovni sistem u kojem se analizira uvođenje Cloud Computing tehnologija i automatizacije podrške jeste Yettel d.o.o. Srbija, jedan od vodećih telekomunikacionih operatora na teritoriji Republike Srbije. Yettel predstavlja deo šire multinacionalne e& PPF Telekom Grupe, koja vrši operacije u zemljama Centralne i Istočne Evrope sa fokusom na pružanje vrhunskog servisa i korisničkog iskustva u sferi digitalnih i telekomunikacionih usluga [4]. U prošlosti Yettel kompanija je na ovom tržištu uspešno poslovala pod brendom Telenor, donoseći brojne inovacije na lokalno tržište mobilnih komunikacija, nastavljajući da širi spektar svojih delatnosti.

Glavno sedište kompanije nalazi se u Beogradu, dok je njeno prisustvo na terenu obezbeđeno kroz razgranatu mrežu od preko 130 poslovnica i prodajnih mesta širom zemlje [4].

Kompanija Yettel Srbija trenutno zapošljava preko 1946 stručnjaka [7] iz različitih oblasti, dok na nacionalnom nivou pruža usluge bazi od približno 3 miliona aktivnih korisnika mobilne mreže [6]. Pored toga, više od 1,5 miliona klijenata redovno koristi Yettel mobilnu aplikaciju na mesečnom nivou [6].

Yettel Srbija zapošljava veliki broj stručnjaka iz oblasti telekomunikacija, inženjeringa, prodaje i korisničke podrške, sa primarnim poslovnim ciljem da milionima svojih aktivnih korisnika pruži stabilnu, brzu i pouzdanu konekciju. Tržišna pozicija kompanije zasniva se na visokom kvalitetu mrežne infrastrukture, mobilne i televizijske ponude kao i prepoznavanju potreba modernog digitalnog društva. Kroz ulaganja u razvoj 5G mreže i proširenje kapaciteta optičkog interneta, kompanija osigurava maksimalnu stabilnost i brzinu protoka podataka za svoje korisnike. Dok stalnom integracijom novih digitalnih servisa i aplikacija u svoju ponudu odgovara na sva veća očekivanja svojih klijenata.

2.2 PREGLED USLUGA I DELATNOSTI

Iako je u javnosti tradicionalno prepoznat prvenstveno kao mobilni operator, Yettel je tokom godina evoluirao u sveobuhvatnog pružaoca tehnoloških servisa. Njegovu ponudu danas obuhvata širok spektar usluga namenjenih kako privatnim, tako i zahtevnim poslovnim (B2B) korisnicima [5], [8]. Osnovne delatnosti koje kompanija nudi obuhvataju [5], [8]:

- Mobilnu telefoniju: Postpejd i pripejd tarifni paketi, roming dodaci i mobilni internet zasnovan na naprednim 4G i 5G tehnologijama.
- Fiksne usluge: Usluge optičkog interneta izuzetno visokih brzina za domaćinstva i poslovne prostore, obezbeđujući maksimalnu stabilnost i protok podataka bez smetnji.
- Digitalnu televiziju: Napredne platforme za praćenje televizijskog i multimedijalnog sadržaja, integrisane sa interaktivnim funkcijama, personalizovanim preporukama i modernim aplikacijama.
- Prodaju uređaja i prateće opreme: Širok asortiman pametnih telefona, tableta, pametnih satova, modema i druge tehnološke opreme najpoznatijih svetskih proizvođača.
- ICT rešenja za poslovne korisnike: Kompleksna rešenja za sajber bezbednost, umrežavanje lokacija i digitalizaciju poslovanja namenjena isključivo korporativnom sektoru.

Ovakva snažna diversifikacija usluga znači da jedan prosečan korisnik danas često koristi više Yettel-ovih servisa istovremeno, najčešće kroz objedinjene pakete.

2.3 ODRŽIVO POSLOVANJE I EKOLOŠKA SVEST

Ono što izdvaja Yettel kao poslovni sistem na lokalnom tržištu jeste izuzetno snažan fokus na održivost i zaštitu životne sredine, što je duboko integrisano u njihov korporativni identitet. Kompanija se javno obavezala na primenu principa "zelenog" poslovanja što se u ogleda u činjenici da njena kompletna mobilna mreža koristi isključivo električnu energiju dobijenu iz obnovljivih izvora [6].

Yettel sprovodi i masovne programe reciklaže elektronskog otpada, motivišući korisnike širom Srbije da donose stare mobilne telefone, uređaje i baterije na reciklažu. Strateški cilj kompanije je da do 2027. godine sakupi i reciklira najmanje 2.700.000 uređaja [4], [6]. Ovakav pristup ne samo da smanjuje negativan uticaj na planetu, već kreira i specifičan brend sa kojim korisnici žele da se identifikuju, što dodatno produbljuje lojalnost između kompanije i njenih klijenata.

3 ANALIZA POSTOJEĆEG INFORMACIONOG SISTEMA ORGANIZACIJE

Analiza postojećeg informacionog sistema unutar telekomunikacionog sistema kao što je Yettel zahteva sveobuhvatan uvid u tehničke i operativne delove podrške klijentima. Specifični detalji o mrežnim topologijama, internom hardveru i softverskim rešenjima kompanije predstavljaju deo strogo čuvane poslovne tajne i interne bezbednosne politike, zbog čega nisu javno dostupni [9]. Prema tome, ova analiza se prvenstveno zasniva na principima moderne inženjerske prakse i logičkim pretpostavkama o dizajnu tipičnog tradicionalnog on-premise komunikacionog sistema prilagođenog velikim korporacijama (Enterprise sistemi), koje moraju da opsluže bazu od približno 3 miliona aktivnih korisnika.

Trenutni mehanizmi rešavanja korisničkih pitanja primarno su oslonjeni na obične kanale komunikacije, tačnije na tradicionalne call centre i e-mail komunikaciju. Prema analizama menadžmenta informacionih sistema, ovakvi modeli interakcije po svojoj prirodi nose niz operativnih ograničenja, kao što su dostupnost podrške isključivo u okviru definisanog radnog vremena, preopterećenje agenata u periodima visokog intenziteta saobraćaja, te izrazito visoki operativni troškovi održavanja celokupnog sistema [10]. Da bi se razumeo obim neophodnih tehnoloških transformacija potrebno je razumevanje softverske, hardverske, internet i komunikacione infrastrukture analiziranog informacionog sistema Yettel organizacije.

3.1 SPECIFIKACIJA SOFTVERA

Softverska arhitektura kod tradicionalnog korisničko-informativnog sistema u telekomunikacionom sektoru sastoji se od različitih ali čvrsto povezanih aplikativnih modula koji funkcionišu u lokalnom okruženju. Centralnu ulogu u obradi korisničkih zahteva, rutiranju saobraćaja i upravljanju podacima imaju sledeće softverske komponente:

- CRM (Customer Relationship Management) sistem: Predstavlja softversku aplikaciju (industrijski standardi Salesforce ili Oracle Siebel) kojoj agenti u korisničkoj podršci pristupaju putem svojih radnih stanica [11]. Ovaj softver spaja sve relevantne podatke o pretplatnicima, uključujući ugovorne obaveze, aktivne tarifne pakete, istoriju zaduženja i arhivu prethodnih interakcija. U tradicionalnim sistemima ovaj softver istovremeno komunicira sa lokalnim bazama podataka.
- PBX (Private Branch Exchange) i ACD (Automatic Call Distribution) softver: Ovaj softver upravlja telekomunikacionim saobraćajem na aplikativnom nivou, za šta se najčešće koriste Cisco ili Avaya tehnologije [12]. Zadatak PBX sistema je prihvatanje dolaznih telefonskih poziva sa javne mreže i njihovo prosleđivanje ka IVR (Interactive Voice Response) podsistemu. Softver za automatsku distribuciju poziva (ACD) zatim koristi definisane algoritme kako bi alocirao pozive unutar redova čekanja prema slobodnim operaterima.

- Sistem za tiketing i upravljanje incidentima: Kada se korisnički problem ne može rešiti tokom prvog kontakta, softver za tiketing omogućava agentu kreiranje digitalnog naloga koji se prosleđuje višim nivoima tehničke podrške [13].
- KMS (Knowledge Management System) - Softver za upravljanje bazom znanja: Koristi se kao centralni interni repozitorijum dokumenata, cenovnika i pravnih procedura. Tokom aktivnog razgovora, agent vrši manuelnu pretragu baze znanja unošenjem ključnih reči u pretraživač [14].

3.2 RAČUNARSKA I HARDVERSKA OPREMA

Pouzdanost i performanse softverskih rešenja u velikoj meri zavise od stabilnosti hardvera na kome su ona implementirana. Telekomunikacioni sistemi se pretežno oslanjaju na kompleksnu on-premise infrastrukturu lociranu u namenskim lokalnim data centrima [15]. Ovakav pristup podrazumeva kompletno vlasništvo, upravljanje i neprekidno fizičko održavanje hardverskih resursa od strane internog IT sektora, što stvara visoke fiksne operativne troškove bez obzira na procenat trenutne iskorišćenosti samog hardvera.

Hardverski ekosistem tradicionalne podrške obuhvata sledeće tri primarne kategorije opreme:

- Lokalni serveri i sistemi za skladištenje podataka (Data centri): Fizičku osnovu sistema čine višenamenski blade serveri montirani u standardne rack ormare, koji obezbeđuju procesorsku snagu i privremenu radnu memoriju neophodnu za izvršavanje CRM aplikacija [15]. Pored samih serverskih jedinica, kritičnu komponentu predstavljaju nizovi diskova velike gustine (mreže za skladištenje podataka, SAN ili NAS sistemi) namenjeni za hostovanje relacionih baza podataka, čuvanje internih dokumenata organizacije i dugoročno arhiviranje audio zapisa obavljenih telefonskih razgovora. Ovakva fizička infrastruktura zahteva strogo kontrolisane uslove što podrazumeva implementaciju industrijskih HVAC (Heating, Ventilation, and Air Conditioning) sistema za neprekidno hlađenje sistema neprekidnog napajanja (UPS uređaji i dizel generatori) i sistema za automatsko rano gašenje požara [16]. Fizičko starenje i amortizacija ovih komponenti zahtevaju periodične i cikluse zamene hardvera.
- Radne stanice korisničkih agenata: Operateri u kontakt centrima koriste stotine fizičkih desktop računara ili prenosivih radnih stanica kako bi pristupili softverskom interfejsu i obavljali svakodnevne zadatke [17]. Svaka pojedinačna radna stanica mora posedovati hardverske specifikacije za istovremeno izvršavanje CRM klijenta, softvera za telefoniju, web pretraživača i internih aplikacija za timsku komunikaciju. Upravljanje ovakvim decentralizovanim hardverskim slojem zahteva stalno angažovanje timova tehničke podrške na terenu koji su zaduženi za konfiguraciju operativnih sistema, lokalno instaliranje bezbednosnih zakrpa, konfigurisanje antivirusne zaštite i otklanjanje fizičkih kvarova na perifernim uređajima.

- Telekomunikaciona i lokalna mrežna oprema: Prijem i obrada masovnog VoIP (Voice over IP) saobraćaja zahteva namensku telekomunikacionu opremu na nivou lokalne mreže. Agenti su opremljeni hardverskim IP telefonima i profesionalnim naglavnim slušalicama sa funkcijama za suzbijanje buke, koji vrše digitalizaciju i kompresiju ljudskog glasa u realnom vremenu [18]. Na mrežnom nivou povezivanje radnih stanica i telefona vrši se preko lokalnih switch-eva koji moraju podržavati PoE (Power over Ethernet). Korporativni ruteri moraju imati kompleksno konfigurisane QoS (Quality of Service) protokole kako bi se mrežni paketi koji prenose glas prioritetizovali u odnosu na standardni prenos podataka, čime se sprečava pojava latencije i seckanja zvuka tokom razgovora sa klijentima.

3.3 KOMUNIKACIONA INFRASTRUKTURA I POVEZIVANJE SA INTERNETOM


U sektoru telekomunikacija, stabilnost i propusna moć komunikacione mreže predstavljaju preduslov za održavanje poslovnih procesa i pružanje neprekidne korisničke podrške. Tradicionalni kontakt centri zahtevaju robusnu mrežnu arhitekturu sposobnu da istovremeno obradi hiljade glasovnih kanala i prenos podataka bez gubitka paketa i kašnjenja [19]. S obzirom na to da sistem mora biti dostupan u režimu 24/7/365, komunikacioni sloj se projektuje sa visokim stepenom tolerancije na otkaz što podrazumeva potpunu hardversku i softversku otpornost na svim nivoima povezivanja. Komunikaciona infrastruktura sistema oslanja se na sledeće elemente:

- Mrežni linkovi, redundantnost i prenos saobraćaja: Povezivanje centralnog data centra sa lokalnim kancelarijama, eksternim mrežama i internet provajderima realizovano je preko namenskih, zakupljenih optičkih linija velike brzine koje garantuju protok saobraćaja [19]. Kako bi se osigurao nesmetan rad u slučaju fizičkog prekida primarnog optičkog kabla, sistem koristi potpuno nezavisne backup mrežne rute koje obezbeđuje sekundarni provajder. Komunikacija između samog korisnika i operatera inicira se putem javne telefonske mreže ili internet protokola (SIP trunking tehnologija), gde se analogni glasovni signal konvertuje u digitalne pakete [20]. Ovi paketi se unutar korporativne mreže usmeravaju primenom MPLS (Multiprotocol Label Switching) protokola, koji omogućava kreiranje virtuelnih privatnih staza i garantuje visok nivo performansi.
- Mrežna bezbednost i enkripcija podataka: Zaštita osetljivih korisničkih podataka i odbrana internih servera od spoljnih sajber pretnji (DDoS napada ili pokušaja neovlašćenog upada) sprovodi se na samoj granici mreže [21]. Na mestu spajanja interne infrastrukture sa internetom pozicionirani su hardverski firewall uređaji sledeće generacije (engl. Next-Generation Firewalls - NGFW) koji vrše duboku inspekciju mrežnih paketa, filtriranje saobraćaja na aplikativnom nivou i prevenciju upada u realnom vremenu. Unutrašnja mreža je dodatno segmentisana tako da se javno dostupni servisi (poput e-mail servera) nalaze u izolovanoj DMZ (demilitarizovanoj) zoni, čime se sprečava direktan pristup bazi podataka i CRM sistemu. Kada operateri obavljaju poslove na daljinu, pristup informacionom sistemu kompanije dozvoljen je isključivo kroz kriptovane VPN (Virtual Private Network) tunele koji koriste IPsec ili TLS protokole, čime se obezbeđuje puna poverljivost i integritet prenesenih informacija [22].

3.4 ŠEMA POSTOJEĆEG INFORMACIONOG SISTEMA

Rešavanje korisničkih upita u tradicionalnom modelu primarno je oslonjeno na on-premise resurse a celokupna arhitektra je dizajnirana kao kompleksan Enterprise sistem sa visokim stepenom redundantnosti kako bi podržala bazu od približno 3 miliona aktivnih korisnika.

Hardverske komponente u lokalnom data centru i prateći softverski moduli stvorili su jedan zatvoren ekosistem čiji je rad podeljen u pet logičkih i bezbednosnih zona.




Slika 1: Celokupna šema arhitekture

Na slici 1. može se videti celokupna šema arhitekture i infrastrukturnog workflow-a postojećeg on-premise sistema.

U nastavku je izvršena podela celokupne arhitekture kroz pojedinačne zone, uz analizu radnih procesa i međusobnih veza.

3.4.1 ZONA 1: SPOLJNO OKRUŽENJE I KORISNIČKI KOMUNIKACIONI KANAL




Slika 2: Prikaz komponente spoljnog okruženja i korisničkih kanala (Zona 1)

Zona 1 koja je predstavljena na slici 2. predstavlja polaznu tačku ekosistema i obuhvata javne komunikacione mreže kroz koje pretplatnici iniciraju interakciju sa tehničkom i informativnom podrškom operatera.

Ona je jednosmernim i dvosmernim vezama povezana direktno sa Zonom 2 (Bezbednosni perimetar) preko ulaznih komunikacionih linkova provajdera.

Tok procesa započinje kada korisnik generiše upit. Ako se radi o glasovnom pozivu, saobraćaj se usmerava preko Javne Telefonske Mreže (PSTN). U slučaju digitalnih kanala, upit se prenosi preko javnog interneta koristeći standardne internet protokole i SIP trunking tehnologiju za konverziju analognog glasovnog signala u digitalne pakete.

3.4.2 ZONA 2: BEZBEDONOSNI PERIMETAR I GRANICA MREŽE




Slika 3: Arhitektura bezbednosnog perimetra i demilitarizovane zone (Zona 2)

Zona 2 na slici 3. predstavlja kritičnu tačku odbrane i filtriranja na samoj granici korporativne mreže kompanije, zaduženu za zaštitu internih servera od spoljnih sajber pretnji i DDoS napada.

Ova zona prima sirovi saobraćaj iz Zone 1, vrši njegovu inspekciju, a zatim prečišćene pakete prosleđuje u Zonu 3 (Interna mreža). Takođe, preko VPN gateway-a ostvaruje povratnu vezu sa dislociranim agentima iz Zone 5.

Dolazni mrežni linkovi se prihvataju preko namenskih optičkih linija projektovanih sa primarnom i backup rutom radi tolerancije na otkaz. Saobraćaj odmah ide na hardverske Firewall uređaje sledeće generacij koji vrše duboku inspekciju paketa i filtriranje na aplikativnom nivou. Unutar ove zone implementirana je izolovana DMZ zona u kojoj se nalazi javno dostupni e-mail server, čime se sprečava direktan kontakt spoljnih korisnika sa bazama podataka. Paralelno, VPN Gateway upravlja kriptovanim IPsec i TLS tunelima koji omogućavaju bezbedan rad operatera na daljinu.

3.4.3 ZONA 3: KORPORATIVNA MREŽNA INFRASTRUKTURA




Slika 4: Struktura korporativne mrežne infrastrukture i rutiranja (Zona 3)

Kao što vidimo na slici 4. ova zona predstavlja centralni komunikacioni put unutar organizacije, zadužen za pametno rutiranje saobraćaja, prioritizaciju paketa i distribuciju napajanja do krajnjih uređaja.

Zona 3 deluje kao posrednik zato što je povezana sa Zonom 2 (odakle prima autorizovani saobraćaj), Zonom 4 (razmenjuje podatke sa serverima pod visokom propusnom moći) i Zonom 5 (fizički povezuje radne stanice agenata).

Mrežni paketi koji prođu NGFW usmeravaju se kroz korporativne rutere primenom MPLS protokola koji kreira virtuelne privatne staze. Na ruterima su konfigurisani strogi QoS protokoli koji glasovnim VoIP paketima daju apsolutni prioritet u odnosu na standardni prenos podataka, sprečavajući latenciju i seckanje zvuka. Sa rutera saobraćaj prelazi na lokalne PoE switch-eve koji istovremeno prenose i podatke i električnu energiju do krajnjih tačaka kontakt centra.

3.4.4 ZONA 4: LOKALNI ON-PREMISE DATA CENTAR



Slika 5: Infrastruktura lokalnog on-premise data centra (Zona 4)


Zona 4, prikazana na slici 5. je tehnološko jezgro postojećeg sistema i sastoji se od fizičke infrastrukture, tačnije hardvera, i aplikativnih modula, tačnije softvera, koji se izvršavaju u lokalnom okruženju.

Povezana je dvosmernim linkovima sa Zonom 3 radi obrade upita, dok na aplikativnom nivou direktno hrani interfejs radnih stanica u Zoni 5.


Što se tiče hardverskog sloja, fizičku osnovu čine višenamenski blade serveri montirani u rack ormare, direktno povezani sa SAN/NAS sistemima velike gustine za skladištenje relacionih baza podataka, internih dokumenata i audio arhiva. Ovaj sloj zahteva neprekidnu podršku HVAC sistema za hlađenje, UPS uređaja i dizel generatora.

Softverski se na serverima paralelno izvršava četiri centralne komponente: PBX i ACD softver koji upravlja IVR podsistemom i distribucijom poziva, CRM sistem koji čuva profile pretplatnika i istoriju interakcija, Ticketing sistem za manuelno upravljanje incidentima, i KMS softver za upravljanje internom bazom znanja.

3.4.5 ZONA 5: KONTAKT CENTAR I KRAJNJE TAČKE



Slika 6: Krajnje tačke kontakt centra i operativni interfejsi agenata (Zona 5)



Slika 7: Krajnje tačke kontakt centra i operativni interfejsi remote agenata (Zona 5)

Ova zona, slika 6. i 7. predstavlja krajnju tačku u workflow-u postojećeg sistema, gde se vrši neposredna ljudska interakcija i manuelna obrada korisničkih zahteva.

Fizički je povezana sa PoE switch-evima iz Zone 3. Softverski zavisi od aplikacija iz Zone 4, dok se udaljeni operateri preko javnog interneta i Zone 2 (VPN) mapiraju u sistem.

Korisnički agenti pristupaju sistemu putem desktop radnih stanica i hardverskih IP telefona sa slušalicama. Kada ACD softver isporuči poziv na IP telefon, agent kroz browser manuelno otvara CRM interfejs kako bi pregledao profil pretplatnika. Ukoliko korisnik postavi kompleksno pitanje, agent vrši manuelnu pretragu statičnih datoteka unutar KMS baze znanja unošenjem ključnih reči. Ako se problem ne može rešiti odmah, agent ručno kreira digitalni nalog unutar Tiketing sistema i prosleđuje ga višim nivoima podrške.

3.5 PROBLEMI I USKA GRILA POSTOJEĆEG INFORMACIONOG SISTEMA

Na osnovu prethodno analize svih pet zona postojećeg informacionog sistema, može se zaključiti da tradicionalni on-premise model kompanije Yettel, poseduje niz strukturnih ograničenja. Ovi problemi predstavljaju "uska grla" koja usporavaju proces rešavanja korisničkih zahteva, ograničavaju skalabilnost i generišu nepotrebno visoke troškove. Ključni problemi se mogu grupisati u tri osnovne kategorije [9], [10], [13], [14], [15]:

1. Operativna ograničenja i ljudski faktor
 - Ograničena dostupnost i preopterećenje agenata: Postojeći modeli interakcije dostupni su samo u okviru radnog vremena. U periodima visokog intenziteta saobraćaja redovno dolazi do preopterećenja agenata korisničke podrške, što onemogućava brzu reakciju sistema.
 - Visoko kognitivno opterećenje operatera: Kada korisnik postavi kompleksnije pitanje, agent je primoran da tokom aktivnog razgovora vrši manuelnu pretragu baze znanja (KMS) isključivo unošenjem ključnih reči. Ovakav softverski pristup stvara visoko kognitivno opterećenje za zaposlene, jer brzina i preciznost generisanja odgovora direktno zavise od individualne sposobnosti agenta da se snađe unutar statičnih datoteka.
 - Rizik od grešaka usled manuelne obrade: Tradicionalni sistemi za tiketing nemaju ugrađenu naprednu automatizaciju, već se u potpunosti oslanjaju na manuelni unos kategorija i prioriteta od strane operatera. To povećava rizik od ljudske greške i direktno produžava vreme procesuiranja i rešavanja problema.
2. Tehnička i softverska ograničenja
 - Kašnjenje u odzivu pod velikim opterećenjem: U CRM softver komunicira direktno sa lokalnim bazama podataka. U situacijama kada na mreži nastupe masovni, istovremeni upiti od strane korisnika, ovaj koncept može dovesti do zagušenja i znatnog kašnjenja u odzivu same aplikacije.
 - Odsustvo automatskog skaliranja: Telekomunikacioni sistem pretežno se oslanja na kompleksnu on-premise infrastrukturu lociranu u lokalnim data centrima. Sistem je tehnički rigidan i za razliku od modernih Cloud rešenja, ne poseduje mogućnost brzog i elastičnog skaliranja resursa u trenucima nepredviđenih povećanja u saobraćaju.
3. Finansijski troškovi i kompleksnost održavanja
 - Visoki fiksni operativni troškovi: Kompletно vlasništvo, fizičko upravljanje i neprekidno održavanje hardverskih resursa od strane internog IT sektora stvara visoke operativne troškove. Ovi troškovi su prisutni bez obzira na to koliki je stvarni procenat trenutne iskorišćenosti samog hardvera. Tradicionalni modeli sami po sebi zahtevaju znatno visoke troškove održavanja.

- Skupa amortizacija i infrastruktura: Fizičko starenje i konstantna amortizacija servera zahtevaju periodične i skupe cikluse zamene opreme.
- Kompleksno mrežno okruženje: Virtuelne privatne staze unutar korporativne mreže usmeravaju se primenom MPLS protokola. Iako on garantuje visok nivo performansi, njegovo funkcionisanje dolazi po ceni veoma kompleksnog i skupog održavanja rutera.
- Zahtevna terenska podrška: Upravljanje stotinama decentralizovanih radnih stanica traži stalno angažovanje timova tehničke podrške na terenu radi konfiguracije, instaliranja zakrpa i otklanjanja fizičkih kvarova.

4 UPOREDNI PREGLED TEHNOLOGIJA

Cilj je teorijska i praktična procena dostupnih tehnologija na tržištu koje mogu zameniti zastarele komponente i prevazići uska grla tradicionalnog kontakta centra analiziranog u prethodnom poglavlju rada. Kroz uporedni pregled različitih modela isporuke cloud usluga, platformi javnih cloud provajdera, naprednih arhitektura za obradu prirodnog jezika i modela skladištenja podataka, postaviće se osnova za definisanje optimalnog i ekonomski opravdanog predloga rešenja za unapređenje korisničko-informativnog sistema kompanije Yettel.

4.1 CLOUD COMPUTING NASPRAM ON-PREMISE INFRASTRUKTURE

Tradicionalni on-premise model informacionih sistema oslanja se na nabavku i neprekidno održavanje sopstvenog hardvera, što zahteva velike kapitalne investicije (CapEx) unapred [15]. Infrastruktura se primarno planira prema maksimalno predviđenom, a ne prema prosečnom opterećenju sistema, što uzrokuje nisku iskorišćenost resursa van izvršenih sati uz stalne fiksne troškove napajanja, hlađenja i fizičkog obezbeđenja [16]. Pored toga, manuelno skaliranje lokalne infrastrukture je dugotrajan proces pa nepredviđeni skokovi saobraćaja lako dovode do kašnjenja u odzivu aplikacija ili pada sistema podrške.

Nasuprot tome, Cloud Computing prema definiciji NIST-a omogućava mrežni pristup na zahtev deljenom bazenu podešavajućih resursa uz minimalan menadžerski napor [23]. Ovaj pristup transformiše strukturu troškova u operativne (OpEx) kroz pay-as-you-go model plaćanja po stvarnom trošku [24]. Ključna odlika cloud-a je elastičnost, tačnije sposobnost automatskog prilagođavanja kapaciteta menjanja saobraćaja u realnom vremenu [23], te visoka dostupnost kroz geografski distribuirane zone, čime se eliminiše rizik od pojedinačne tačke otkaza [24]. Na osnovu ovih prednosti, kao i mnogih drugih koje cloud paradigma nudi za resavanje ovog problema, mi nju biramo za unapređenje telekomunikacionog informacionog sistema Yettel-a.

4.2 ANALIZA I SELEKCIJA CLOUD PROVAJDERA ZA IMPLEMENTACIJU

Evaluacija obuhvata tri vodeće platforme na savremenom tržištu: Google Cloud Platform, Microsoft Azure i Amazon Web Services. Cilj je teorijska procena njihove superiornosti i arhitektonske usklađenosti sa zahtevima kontakta centra.

Google Cloud Platform (GCP) obezbeđuje snažan skup alata namenjenih obradi prirodnog jezika i upravljanju podacima, gde centralnu ulogu igra Dialogflow kao SaaS rešenje za razvoj chatbot aplikacija. Ovaj ekosistem se u serverless konfiguracijama oslanja na Cloud Functions za izvršavanje backend logike i Firestore kao NoSQL bazu podataka za skladištenje dokumenata i stanja konverzacije [25]. Iako Dialogflow nudi napredne mogućnosti, njegov model je optimizovan za prepoznavanje namera (Intent Matching), što može uvesti ograničenja i dodatnu složenost prilikom pokušaja implementacije čistih, dinamičkih sistema za pretragu i generisanje odgovora zasnovanih na eksternim bazama znanja organizacije.

Microsoft Azure nudi robustan i bezbedan okvir prilagođen korporativnim sistemima, implementirajući Azure Bot Service kao primarni interfejs za komunikaciju sa korisnicima i upravljanje kanalima [26]. Pozadinska arhitektura se u ovom slučaju oslanja na Azure Functions u FaaS domenu, dok se perzistencija podataka i logovanje konverzacija obavljaju kroz skalabilnu NoSQL bazu podataka Cosmos DB. Uprkos visokom nivou pouzdanosti i direktnoj integraciji sa Microsoft poslovnim okruženjem, Azure ekosistem često zahteva kompleksnije infrastrukturno povezivanje i upravljanje dozvolama, što može umanjiti fleksibilnost i brzinu razvoja u izolovanim projektima koji zahtevaju agilnu orkestraciju modela.

Amazon Web Services (AWS) se naprednošću svoje serverless ponude i ekosistema servisa nameće kao optimalan izbor za realizaciju ovog projekta. Opredeljenja za AWS počiva na tehnološkoj superiornosti potpuno upravljanog servisa Amazon Bedrock, koji omogućava direktan, bezbedan i centralizovan pristup naprednim osnovnim modelima kao što su Claude i Titan bez napuštanja cloud perimetra [27]. Integracija Bedrock-a sa serverless računarskim resursima poput AWS Lambda funkcija [28] i naprednim pay-per-use alternativama za skladištenje eliminiše potrebu za održavanjem operativnih sistema i generiše troškove isključivo u trenucima stvarnog izvršavanja upita. Dodatni kritični faktor predstavlja regionalna dostupnost kompletne infrastrukture kroz eu-central-1 čvorište u Frankfurtu, čime se osigurava minimalno kašnjenje prilikom obrade korisničkih zahteva i potpuna usklađenost sa tehničkim standardima. Sam ekosistem, laka dostupnost i dobra integracija stavljaju AWS kao primarni izbor provajdera za implementaciju rešenja ovog projekta.

4.3 ARHITEKTURE OBRADJE PRIRODNOG JEZIKA: OPŠTI NLP NASPRAM RAG SISTEMA

Dizajn savremenih sistema za korisničku podršku obeležen je prelaskom sa konverzacijskih formi na fleksibilne kognitivne sisteme. Ovde se vrši teorijsko razdvajanje između tradicionalne obrade prirodnog jezika (NLP), zasnovane na klasifikaciji namera, i moderne arhitekture generisanja proširenog pretraživanjem (Retrieval-Augmented Generation ili RAG).

4.3.1 OGRANIČENJA OPŠTEG NATURAL LANGUAGE PROCESSING (NLP)

Tradicionalni NLP alati funkcionišu na bazi prepoznavanja namera (Intent Matching) i popunjavanja slotova (Slot Filling), gde se dolazni korisnički upit matematički klasifikuje i mapira u unapred definisane kategorije [29]. Ovaj pristup ne pokazuje fleksibilnost unutar složenih informacionih sistema jer se celokupan konverzacijski tok usmerava kroz deterministička grafovska stabla odlučivanja. Svako odstupanje od predviđenog scenarija dovodi do pada konverzacijskog toka.

Sistemi poput Google Dialogflow (ES i CX) i Microsoft Azure Bot Service zahtevaju manuelno građenje i dugotrajno održavanje kompleksnih konverzacijskih grafova, što stvara visoke operativne troškove i konstantan angažman inženjera za rekonfiguraciju sistema pri svakoj promeni poslovne logike.

Sa druge strane, analiza servisa Amazon Lex, AWS servis za NLP, ukazuje na stroge geografske i jezičke barijere srpskog jezika.

4.3.2 PREDNOSTI RETRIEVAL-AUGMENTED GENERATION (RAG) ARHITEKTURE

Retrieval-Augmented Generation (RAG) predstavlja hibridnu arhitekturu koja uspešno prelazi prepreku između parametarskog znanja velikih jezičkih modela i neparametarskog znanja eksternih repozitorijuma [30]. U trenutku prijema upita, proces se izvršava u dva ključna koraka: faza pretraživanja (Retrieval) i faza generisanja (Generation). Tokom prve faze, informacioni retriver vrši semantičku pretragu nad internom bazom znanja organizacije i izdvaja najrelevantnije tekstualne segmente na osnovu kosinusne sličnosti unutar vektorskog prostora. U drugoj fazi, ovi segmenti se ubacuju u kontekstualni prozor (Prompt Injection) i prosleđuju generativnom modelu kao čvrsto definisane granice unutar kojih model sintetiše konačan odgovor.

Ova arhitektura se primarno uvodi zbog potpune eliminacije fenomena halucinacija, koji je inherentan čistim jezičkim modelima koji pokušavaju da generišu odgovore oslanjajući se isključivo na informacije zapamćene tokom predtreniranja [30]. Uslovljavanjem modela da koristi samo preuzete odlomke dokumenata, rizik od generisanja netačnih podataka sveden je na minimum. RAG arhitektura je ekonomski i infrastrukturno superiorna u poređenju sa procesom finog podešavanja (Fine-Tuning) celokupnog modela, a ažuriranje baze znanja u RAG sistemu vrši se jednostavnim menjanjem ili dodavanjem tekstualnih dokumenata u skladištu podataka bez ikakvih dodatnih troškova. Istovremeno, savremeni veliki jezički modeli (LLM) pružaju neuporedivo bolje statističko razumevanje srpskog jezika u odnosu na tradicionalni NLP [31]. Kroz masovnu izloženost višejezičnim podacima tokom faze predtreniranja, ovi modeli su razvili duboke unutrašnje reprezentacije semantike i verovatnoća prelaženja tokena, što im omogućava da uspešno interpretiraju morfologiju, sinonime i kontekst bez potrebe za eksternim lokalizovanim jezičkim paketima.

4.3.3 GENERATIVNI AI I MODELI ZA UGRAĐIVANJE (AMAZON BEDROCK, CLAUDE I TITAN)

Praktična realizacija ovog sistema zahteva koordinaciju specijalizovanih servisa unutar zaštićenog cloud okruženja. Amazon Bedrock pruža potpuno upravljani, serverless sloj koji omogućava ujedinjeni pristup vodećim svetskim osnovnim modelima preko jedinstvenog API interfejsa [32]. Bezbednosna arhitektura Bedrock-a garantuje izolaciju podataka, što znači da se korisnički upiti i dokumenti iz lokalnog skladišta nikada ne koriste za javno treniranje komercijalnih modela, niti napuštaju definisani cloud perimetar organizacije. Ovaj pristup eliminiše visoke fiksne troškove hostovanja sopstvene AI infrastrukture na namenskim virtuelnim mašinama i uvodi pay-per-use model naplate po utrošenom tokenu.

U generativnom sloju, model Claude 4.6 Opus kompanije Anthropic izabran je jer koristi naprednu transformer dekodersku arhitekturu sa mehanizmima pažnje optimizovanim za analizu dugih i kompleksnih sintaksičkih struktura unutar kontekstualnog prozora [31]. Pri izboru ovog modela ključni faktor bila je racionalizacija troškova i kvaliteta. Iako na tržištu postoje naprednije i skuplje iteracije modela, poput verzije Claude 4.8, one sa sobom nose znatno višu cenu po tokenu. Za potrebe automatizovanog odgovaranja na korisnička pitanja u ovom projektu, kognitivni kvalitet koji pruža Claude 4.6 Opus je više nego dovoljan. Claude uspešno generiše tekst koji prati tačan ton poslovne komunikacije i savršeno prepoznaje kontekst upita na srpskom jeziku zasnovan na statističkom poklapanju tokena sa interneta [31].

Eksterni modeli, poput OpenAI GPT-4o (preko Azure platforme) ili Google Gemini 1.5 Pro, nude sličan odnos cene i kognitivnog kvaliteta, ali bi njihova implementacija zahtevala eksterne API pozive i napuštanje izolovanog AWS okruženja, čime bi se kompromitovala bezbednosna arhitektura i nepotrebno povećala mrežna latencija.

Sa druge strane, unutar samog Amazon Bedrock ekosistema, alternative u sličnom ili nešto nižem cenovnom rangju obuhvataju modele poput Meta Llama 3 i Mistral Large. Iako ovi modeli nude visoke performanse na engleskom jeziku, Claude 4.6 Opus se izdvaja kao apsolutno najbolji u svojoj klasi zbog neuporedivo naprednijeg statističkog razumevanja morfologije slovenskih jezika [31].

Pre same generacije odgovora, Amazon Titan Text Embeddings V2 model vrši ključni proces vektorizacije teksta [33]. Ovaj model pretvara nestruktuiranu lingvističku formu (reči, rečenice i pasuse) u višedimenzionalne matematičke vektore (guste nizove realnih brojeva) koji reprezentuju njihovo suštinsko semantičko značenje. Titan V2 je izabran kao direktna alternativa open-source embedding modelima, čija bi implementacija zahtevali konstantno pokrenute virtuelne servere (EC2 instance) i stalne fiksne mesečne troškove. Pored toga, Titan V2 nudi tehničku prednost, pretraga se može optimizovati bez značajnog gubitka semantičke preciznosti, što direktno ubrzava izvršavanje upita i drastično umanjuje troškove skladištenja u poređenju sa skupim alternativama poput Amazon OpenSearch Serverless-a, koji generiše visoke fiksne operativne troškove bez obzira na frekvenciju saobraćaja. Odabrani stack omogućava visok nivo stabilnosti uz zadržavanje pay-per-use efikasnosti.

4.4 UPOREDNI PREGLED SISTEMA ZA SKLADIŠTENJE I VEKTORSKU PRETRAGU

Implementacija RAG sistema i pratećih analitičkih modula zahteva pažljivu selekciju tehnologija za skladištenje podataka. Za razliku od tradicionalnih informacionih sistema koji se oslanjaju na jedinstvenu relaciju bazu, moderna Cloud arhitektura nalaže razdvajanje skladišta prema tipu podataka i načinu njihovog pretraživanja.

4.4.1 VEKTORSKE BAZE PODATAKA: OPENSEARCH SERVERLESS NASPRAM AMAZON S3 VECTORS

Arhitektura baze znanja unutar RAG sistema direktno zavisi od performansi i isplativosti vektorskog skladišta. Amazon OpenSearch Serverless predstavlja naprednu i visoko-performansnu tehnologiju koja obezbeđuje trenutno indeksiranje i pretragu miliona višedimenzionalnih vektora uz visoku preciznost [34]. Međutim, ovaj servis sa sobom nosi visoke fiksne operativne troškove, približno 350 dolara mesečno, koji se naplaćuju bez obzira na frekvenciju i obim upita, što ga čini ekonomski neefikasnim za manje sisteme, kao što je naše razvojno-studentsko okruženje za razvoj ovog projekta. U slučaju da se ovakav projekat stvarno razvija na prvoj skali Yettel kompanije, OpenSearch bi bio bolji izbor zbog svojih naprednijih funkcija.

Kao direktna i optimizovana alternativa, Amazon S3 Vectors uvodi potpuno drugačiju, pay-per-use ekonomsku ponudu. Ovaj servis eliminiše fiksne mesečne izdatke i naplaćuje isključivo stvarno izvršene upite i skladišteni kapacitet, čineći ukupne troškove infrastrukture zanemarljivim tokom faze razvoja i validacije projekta [35]. Izbor Amazon S3 Vectors tehnologije pruža maksimalnu efikasnost u radu sa izolovanim dokumentima organizacije, obezbeđujući stabilnu semantičku pretragu bez potrebe za nepotrebnim finansijskim opterećenjem sistema.

4.4.2 LOGOVANJE KONVERZACIJA: RELACIONE NASPRAM NOSQL BAZA PODATAKA (AMAZON DYNAMODB)

Čuvanje istorije razgovora i analitičkih podataka u realnom vremenu zahteva bazu podataka sposobnu da izdrži visok intenzitet asinhronih upisa. Tradicionalne SQL baze podataka označene se striktno struktuiranom šemom i zahtevaju kompleksno i skupo horizontalno skaliranje kako bi odgovorile na masovne, istovremene zahteve u sistemima što može dovesti do zagušenja i kašnjenja u odzivu klijentskih aplikacija [36]. Dok NoSQL baze podataka zasnovane na ključ-vrednost modelu nude ekstremnu fleksibilnost šeme, dozvoljavajući dinamičko dodavanje novih atributa bez izmene strukture tabele i dizajnirane su za linearno horizontalno skaliranje [36].

U ovom domenu, Amazon DynamoDB [37] se izdvaja kao *serverless* NoSQL rešenje koje nudi jednocifreno milisekundno kašnjenje prilikom izvršavanja operacija upisa i čitanja, uz potpuno visoku toleranciju na otkaz. DynamoDB omogućava asinhrono logovanje svake konverzacije tako da pozadinski upisi ne blokiraju chat interfejs korisnika. Dodatna prednost za analitički modul jeste podrška za atomske operacije ažuriranja, što omogućava pouzdano i trenutno inkrementiranje statističkih brojača po temama i datumima, uklanjajući potrebu za kompleksnim transakcionim mehanizmima.

4.5 SISTEMI ZA SERVERLESS IZVRŠAVANJE I UPRAVLJANJE API ZAHTEVIMA

Prihvatanje i obrada korisničkih zahteva u Cloud sistemima zahtevaju stabilno i fleksibilno okruženje koje može trenutno da odgovori na promenljiv intenzitet saobraćaja bez potrebe za stalnim angažovanjem i rezervisanjem fiksnih infrastrukturnih kapaciteta. Ovo se završava sa mehanizmima koji omogućavaju da se serverski kod izvršava i API zahtevi rutiraju potpuno autonomno, bez potrebe za zakupom, konfigurisanjem ili neprekidnim radom klasičnih virtuelnih mašina.

4.5.1 TRADICIONALNO HOSTOVANJE APLIKACIJA NASPRAM FAAS (FUNCTION-AS-A-SERVICE) MODELA

Tradicionalni model hostovanja aplikacija podrazumeva stalno zakupljene virtuelne servere ili fizičke sisteme koji moraju da rade neprekidno kako bi aplikacija uvek bila dostupna korisnicima. Ovakav pristup zahteva konstantno administrativno održavanje operativnog sistema, ručno konfigurisanje mrežnih parametara, kao i stalnu instalaciju bezbednosnih zakrpa [38]. Tradicionalni serveri troše računarsku snagu i generišu troškove čak i u periodima kada nema aktivnih korisničkih upita.

Nasuprot tome, funkcija kao servis, kroz tehnologije poput servisa AWS Lambda, uvodi arhitekturu vođenu događajima gde se računarski resursi alociraju potpuno automatski tek u trenutku kada se specifičan korisnički zahtev manifestuje [39]. Pozadinski kod se izvršava isključivo u trajanju samog upita, nakon čega se svi alocirani resursi odmah oslobađaju. Ovim se postiže prelazak na pay-as-you-go model gde se naplata vrši u milisekundama stvarnog vremena izvršavanja, dok su troškovi tokom perioda neaktivnosti svedeni na nulu. Ovaj pristup u potpunosti eliminiše potrebu za održavanjem operativnih sistema, omogućavajući automatsko i praktično neograničeno skaliranje od nule do stotina istovremenih zahteva, bez ikakvog rizika od preopterećenja pozadinske infrastrukture [39].

4.5.2 UPRAVLJANJE SAOBRAĆAJEM POMOĆU API GATEWAY-A

Da bi klijentski interfejs, frontend, mogao bezbedno i efikasno da komunicira sa backend funkcijama, neophodan je centralizovani ulazni sloj za upravljanje saobraćajem. Amazon API Gateway predstavlja potpuno upravljani servis koji deluje kao jedinstvena ulazna tačka za sve dolazne HTTP zahteve sa javnog interneta [40]. Ovaj servis omogućava definisanje i izlaganje struktuiranih REST API interfejsa preko kojih klijentska aplikacija šalje tekstualne poruke korisnika i preuzima dodate podatke za potrebe analitičkog modula.

Značaj REST API interfejsa ogleda se u bezbednom i kontrolisanom rutiranju saobraćaja između korisničkog pretraživača i backend logike. API Gateway obezbeđuje potpunu izolaciju unutrašnjih funkcija od spoljnog sveta, sprečavajući direktno izlaganje koda i baza podataka potencijalnim malicioznim upadima [41]. Pored prosleđivanja poruka, ovaj sloj automatski upravlja kritičnim funkcijama kao što su podešavanja deljenja resursa između različitih domena (CORS), provera autentičnosti zahteva, i kontrola protoka saobraćaja (Throttling) koja štiti pozadinske Lambda funkcije od namernog ili slučajnog preopterećenja prevelikim brojem istovremenih upita [40], [41].

4.6 HOSTING PREZENTACIONOG SLOJA I ANALITIKA

Spajanje klijentske strane i pozadinske logike u funkcionalnu celinu zahteva stabilan mehanizam za isporuku korisničkog interfejsa, kao i sistem za praćenje rada svih komponenti u realnom vremenu.

4.6.1 STATIČKI HOSTING (AMAZON S3): TRADICIONALNI VEB-SERVERI NASPRAM OBJECT STORAGE HOSTINGA

Tradicionalni pristup isporuci korisničkog interfejsa podrazumeva upotrebu namenskih veb-servera kao što su Apache ili Nginx, koji su instalirani na fizičkim ili virtuelnim mašinama. Ovi serveri rade neprekidno i stalno troše procesorsku snagu i radnu memoriju kako bi osluškivali dolazne HTTP zahteve, upravljali rutiranjem i isporučivali statičke resurse (HTML, CSS, JavaScript i slike) klijentima.

Nasuprot tome, hosting na sistemima za skladištenje objekata, kroz servis Amazon S3, potpuno eliminiše računarski veb-slojeve za statičke resurse. Unutar ove arhitekture, datoteke frontenda se tretiraju kao nepromenljivi objekti koji se isporučuju direktno klijentskom pretraživaču preko ugrađenog HTTP/HTTPS interfejsa. Amazon S3 statički hosting nativno obezbeđuje visoku dostupnost i automatsko skaliranje, što znači da sistem može da izdrži masovne skokove saobraćaja bez ikakve potrebe za upravljanjem serverima ili rezervisanjem kapaciteta [42]. Ovo je posebna pogodnost jer za potrebe ovog projekta biće korišćeni single-page sajtovi, čiji zahtevi su daleko ispod tradicionalnih veb-servera.

4.6.2 INFRASTRUKTURNI NADZOR (AMAZON CLOUDWATCH)

Distribuirani Cloud sistemi, koji se sastoje od većeg broja izolovanih mikroservisa, Lambda funkcija i baza podataka, unose specifičnu kompleksnost u pogledu praćenja rada i otkrivanja nepravilnosti. Budući da se izvršavanje jednog korisničkog zahteva proteže kroz više nezavisnih komponenti, tradicionalne metode lokalnog logovanja postaju neupotrebljive.

Amazon CloudWatch obezbeđuje ovu neophodnu centralizovanu vidljivost prikupljanjem i organizovanjem metričkih podataka i logova u realnom vremenu [43]. Za sisteme zasnovane na serverless arhitekturi, praćenje metrika performansi, kao što je vreme izvršavanja funkcija, ima kritičnu ulogu u sprečavanju prekida rada usled dostizanja maksimalnog dozvoljenog vremenskog limita. CloudWatch omogućava inženjerima da kroz log grupe vrše dijagnostiku grešaka i prate stope neuspehli izvršavanja bez dodavanja opterećenja samoj aplikativnoj logici.

5 PREDLOG REŠENJA ZA UNAPREĐENJE POSLOVNOG SISTEMA

5.1 KONCEPTUALNI DIZAJN I FUNKCIONALNI MODEL PREDLOŽENOG REŠENJA

Uvođenje Serverless AI chatbot asistenta menja sistem korisničke podrške kompanije Yettel Srbija, transformišući reaktivan i manuelni sistem u automatizovani, uvek dostupni informativni ekosistem. Funkcionalni model rešenja posmatra se iz dve ključne perspektive: iz ugla krajnjeg korisnika i iz operativnog ugla organizacije.

1. Funkcionalnost iz ugla korisnika usluga

Uz novo rešenje, korisnici više nisu ograničeni radnim vremenom tradicionalnog kontakt centra, niti su primorani da čekaju na slobodnog operatera tokom perioda visokog intenziteta saobraćaja na mreži.


Novi sistem se korisniku prikazuje kao interaktivni, lebdeći web widget, koji je integrisan na zvaničnom Yettel portalu. Umesto kretanja kroz hijerarhije menija ili čekanja na e-mail odgovor, korisnik može u bilo kom trenutku, 24/7, da otvori chat prozor i postavi pitanje na srpskom jeziku. Veštačka inteligencija prepoznaje nameru i sintaksu korisnika, i u realnom vremenu isporučuje precizan, tačan i kontekstualno relevantan odgovor. Oslanjanjem isključivo na zvanične interne procedure i dokumente kompanije, korisniku se pruža visoka pouzdanost i tačnost pruženih informacija vezanih za tarife, uređaje, podešavanja ili reklamacija.

2. Funkcionalnost iz ugla kompanije Yettel

Iz operativnog i poslovnog ugla, implementacija ovog rešenja donosi drastično smanjenje pritiska na ljudske resurse. AI asistent automatski preuzima i rešava masovne, svakodnevne i rutinske upite, delujući kao pouzdan prvi nivo podrške. Ovo direktno omogućava kompaniji da optimizuje svoje operativne troškove i preusmeri kognitivni fokus svojih agenata na rešavanje naprednih, kompleksnih zahteva koji zahtevaju ljudsku intervenciju i tehničku ekspertizu.

Pored neposredne komunikacije, predloženi sistem stvara vrednost kroz potpuno nezavisan analitički modul kojem pristupa menadžment. Kroz siguran administratorski panel organizacija dobija vizuelni prikaz kategorizacije svake obavljene konverzacije, grupišući ih u teme poput reklamacija, interneta ili upita o tarifama. Sistem pozadinski, potpuno autonomno, vrši analizu. Ovakav pristup menadžmentu pruža jasan, neprekidan uvid u najčešće probleme sa kojima se klijenti suočavaju u datom trenutku, omogućavajući pravovremeno reagovanje i donošenje informisanih poslovnih odluka.

5.2 ARHITEKTURA PREDLOŽENOG CLOUD REŠENJA



Slika 8: Šema arhitekture Cloud serverless AI chatbot sistema.

Dizajn predloženog rešenja podeljen je u nekoliko nezavisnih, ali čvrsto integrisanih tehnoloških slojeva lociranih unutar jedinstvenog izolovanog cloud regiona (eu-central-1). Komponente komuniciraju isključivo putem sigurnih API interfejsa, obezbeđujući maksimalnu toleranciju na otkaz, visoku dostupnost sistema i automatsko prilagođavanje resursa u realnom vremenu.

Šema na slici 8. prikazuje celokupan tok podataka i interakcija unutar sistema. Arhitektura se logički deli na nekoliko slojeva.

1. Prezentacioni sloj (Frontend)

Ovde se vrši interakcija korisnika sa sistemom, kao i uvid u statistiku od strane administratora, odvija se preko optimizovanih web interfejsa. Kako bi se izbegli fiksni operativni troškovi održavanja klasičnih web servera i omogućila brza isporuka sadržaja, celokupan korisnički interfejs (klijentski widget i administratorski panel koje ćemo kasnije videti) hostuje se kao statički resurs direktno na sistemu za skladištenje objekata Amazon S3. Ovaj pristup garantuje trenutnu dostupnost interfejsa bez obzira na broj istovremenih posetilaca, uklanjajući potrebu za upravljanjem hardverom na strani klijenta.

2. Komunikacioni sloj

Svi upiti generisani u pretraživaču usmeravaju se ka centralizovanom pristupnom čvoru kroz servis Amazon API Gateway. Ovaj sloj deluje kao primarni štit i usmerivač mrežnog saobraćaja. On obezbeđuje strukturirane REST API interfejsse, sa specifičnim rutama (/chat i /analytics), koji primaju dolazne HTTP zahteve sa javnog interneta i prosleđuju ih isključivo autorizovanim unutrašnjim funkcijama, štiteći tako pozadinsku logiku od direktnog izlaganja i preopterećenja.

3. Aplikativni sloj (Serverless)

Glavna procesorska logika sistema izvršava se kroz Function-as-a-Service korišćenjem servisa AWS Lambda. Računarski resursi u ovom modelu ne postoje u stanju mirovanja, već oni se dinamički alociraju isključivo u trenutku kada API Gateway prosledi korisničku poruku ili zahtev. U sistemu su implementirane dve nezavisne funkcije. Prva funkcija vrši parsiranje dolaznih upita korisnika, detekciju tema i orkestraciju poziva ka veštačkoj inteligenciji. Druga, potpuno izolovana funkcija, zadužena je isključivo za skeniranje baze podataka i agregaciju statističkih vrednosti koje se vraćaju na administratorski panel.

4. Kognitivni sloj (RAG)

Kognitivne sposobnosti sistema oslanjaju se na naprednu RAG arhitekturu uspostavljenu servisom Amazon Bedrock-a. Time se u potpunosti prevazilaze ograničenja tradicionalnih sistema za obradu prirodnog jezika (NLP). Kada korisnik postavi pitanje, model za vektorizaciju, Amazon Titan Text Embeddings V2, analizira tekstualni unos i vrši duboku semantičku pretragu nad vektorskom bazom Amazon S3 Vectors. Ova baza funkcioniše kao izolovan repozitorijum u kojem su smeštena isključivo interna dokumenta kompanije. Pronađeni segmenti dokumenata prenose se generativnom velikom jezičkom modelu, Claude 4.6 Opus, koji na osnovu njih sintetiše stručan, kontekstualno precizan odgovor na jeziku korisnika, eliminišući mogućnost generisanja neproverenih informacija ili AI halucinacija.

5. Sloj podataka

Perzistencija podataka i vođenje statistike realizovani su asinhrono, upotrebom potpuno upravljane NoSQL baze podataka, Amazon DynamoDB. Njena infrastruktura obezbeđuje milisekundno kašnjenje prilikom čitanja i upisa logova svake konverzacije. Paralelno sa čuvanjem istorije razgovora, aplikativni sloj koristi atomske operacije ažuriranja kako bi automatski inkrementirao analitičke brojače prema detektovanoj temi i datumu. Ovakav koncept razdvajanja skladištenja omogućava pouzdano i trenutno generisanje analitike za menadžment bez blokiranja tabela ili stvaranja kašnjenja na klijentskom interfejsu.

5.3 OBIM UNAPREĐENJA I UTICAJ NA POSLOVNI SISTEM

Implementacija predloženog Serverless AI Chatbot rešenja na AWS Cloud platformi predstavlja inženjerski odgovor na identifikovana operativna, tehnička i finansijska uska grla tradicionalnog on-premise sistema. Uvođenjem arhitekture zasnovane na RAG tehnologiji, uticaj na poslovni sistem kompanije Yettel se može povećati i posmatrati kroz dva različita nivoa integracije u poslovnoj praksi.

5.3.1 HIBRIDNO UNAPREĐENJE SISTEMA

Ovaj model predstavlja primarni i operativno najopravdaniji scenario trenutne implementacije. U hibridnom okruženju, kontakt centar zadržava svoju funkciju, ali AI asistent preuzima ulogu prvog nivoa (Tier 1) tehničke i informativne podrške. Na ovom nivou, predloženo rešenje direktno rešava sledeća uska grla:

- Ograničena dostupnost i zagušenje sistema: Ovaj problem se uspešno prevazilazi uvođenjem Chatbot-a koji funkcioniše 24/7/365, eliminišući barijere ograničenog radnog vremena i redova čekanja u periodima visokog saobraćaja. Tehnički aspekt kašnjenja u odzivu, karakterističan lokalnu infrastrukturu, rešava se Serverless modelom koji računarske resurse elastično i automatski skalira na osnovu trenutnih potreba.
- Visoko kognitivno opterećenje agenata: Pritisak na operativni tim se drastično smanjuje automatskim procesuiranjem masovnih i rutinskih korisničkih upita u vezi sa opštim informacijama, internetom i procedurama. Operateri više nisu primorani da pod pritiskom manuelno pretražuju baze znanja (KMS), čime se minimizuje rizik od ljudske greške.
- Fokusiranje ljudskih resursa na kompleksne zadatke: Oslobođeni repetitivnih poslova, korisnički agenti mogu da preusmere svoju punu pažnju i kapacitete isključivo na rešavanje složenih tehničkih problema i naprednih reklamacija, koje po svojoj prirodi zahtevaju ljudsku ekspertizu.

5.3.2 POTPUNA AUTOMATIZACIJA

Posmatrano iz teorijske perspektive, predloženi sistem poseduje arhitektonski potencijal za potpunu transformaciju interakcije sa klijentima. U ovom scenariju, Chatbot bi prevazišao ulogu isključivo informativnog widget-a i postao centralni poslovni interfejs kompanije, obavljajući duboku integraciju ne samo sa dokumentima, već i sa transakcionim relacionim bazama i centralnim CRM sistemom. To bi omogućilo:


- Potpunu autonomiju klijenata: Na ovoj skali, AI asistent bi u potpunosti zamenio ulogu tradicionalnog informacionog sistema. Korisnicima bi bilo omogućeno da, putem prirodnog razgovora umesto navigacije kroz složene menije, samostalno i trenutno obavljaju kompleksne operacije, poput promene tarifnih paketa, plaćanja računa ili provere tehničkih smetnji.
- Redukcija operativnih troškova: Ovakav obim automatizacije eliminisao bi potrebu za izuzetno visokim fiksnim troškovima održavanja celokupne on-premise infrastrukture. Prelazak na pay-as-you-go Cloud model oslobodio bi kompaniju od skupe amortizacije ogromnih lokalnih data centara, glomaznih PBX/ACD komunikacionih sistema i neprekidne terenske podrške decentralizovanim radnim stanicama.
- Napredno odlučivanje vođeno podacima: Upotrebom nezavisnog AWS analitičkog modula na velikoj skali, menadžment bi dobio jasan, automatizovan uvid u stanje celokupne korisničke baze od preko 3 miliona pretplatnika u realnom vremenu. Ovo bi omogućilo agilno donošenje informisanih poslovnih odluka i kreiranje hiper-personalizovanih ponuda.

6 IMPLEMENTACIJA REŠENJA ZA UNAPREĐENJE POSLOVNOG SISTEMA

U nastavku se prikazuje praktična realizacija predloženog Cloud rešenja u prethodnom poglavlju, prateći sve korake razvoja od konfiguracije bezbednosnih polisa do finalne integracije prezentacionog sloja.


6.1 INICIJALIZACIJA CLOUD OKRUŽENJA I KONTROLA PRISTUPA

Implementacija počinje sa inicijalizacijom infrastrukture unutar Amazon Web Services (AWS) Cloud okruženja, kao što je prikazano na slici 9. Celokupan sistem implementiran je u regionu eu-central-1 (Frankfurt) kako bi se osigurala minimalna mrežna kašnjenja.



Slika 9: AWS okruženje konzole.


Prvi korak u implementaciji obuhvatao je uspostavljanje pristupa neophodnim Foundation modelima unutar servisa Amazon Bedrock. Odabrani modeli su Amazon Titan Text Embeddings V2, za vektorsku reprezentaciju teksta i Claude 4.6 Opus za potrebe LLM generisanja, prikazani na slici 10. Pristup ovim modelima je ostvaren kroz mehanizam automatskog omogućavanja, "First Invoke" pristup. Modeli su inicijalizovani i uspešno aktivirani direktno kroz AWS Model Catalog, što je potvrđeno prvim probnim pozivom unutar ugrađenog Playground okruženja.




Slika 10: Prikaz modela Titan Text Embeddings V2 i Claude Opus 4.6 u katalogu modela .

Nakon pristupa kognitivim modelima, uspostavljen je striktan mehanizam kontrole pristupa kreiranjem Identity and Access Management (IAM) rola. Kako bi se ispoštovao bezbednosni princip najmanjih privilegija, za sigurnu komunikaciju između izolovanih servisa kreirane su dve primarne korisničke uloge, prikazano na slici 11.:


1. YettelChatbotLambdaRole: Ova izvršna rola dodeljena je pozadinskim funkcijama (AWS Lambda) i konfigurisana je tako da dozvoljava isključivo akcije neophodne za obradu korisničkih upita i analitiku. Uključene su polisama definisane dozvole za pozivanje modela i generisanje odgovora iz baze znanja (bedrock:RetrieveAndGenerate, bedrock:InvokeModel), asinhroni upis i agregaciju nad NoSQL bazama podataka (dynamodb:PutItem, dynamodb:UpdateItem, dynamodb:Scan, dynamodb:Query), kao i standardne dozvole za beleženje operativnih logova u nadzorni sistem (logs:CreateLogGroup, logs:CreateLogStream, logs:PutLogEvents), kao što se vidi na slici 12.
2. YettelChatbotAPIGatewayRole: Ova rola je namenski kreirana i dodeljena Amazon API Gateway servisu kako bi mu se omogućilo bezbedno prosleđivanje mrežnih metrika i dnevnika zahteva u Amazon CloudWatch sistem. Kao na slici 13. za ovu namenu iskorišćena je predefinisana AWS polisa pod nazivom AmazonAPIGatewayPushToCloudWatchLogs.



Slika 11: Kreirane korisničke role.



Slika 12: YettelChatbotLambdaRole permisije.




Slika 13: Predefinisana AWS permisija za YettelChatbotAPIGatewayRole.

6.2 KONFIGURACIJA SISTEMA ZA PERZISTENCIJU PODATAKA


Nakon uspostavljanja kognitivnog okvira, bezbednosti i kontrole pristupa, realizovana je praktična konfiguracija sloja za perzistenciju podataka. Ovaj deo sistema oslanja se na kombinaciju objektnog skladišta (Amazon S3) i serverless NoSQL baze podataka (Amazon DynamoDB).

U okviru servisa Amazon S3, kreirana su dva namenska kontejnera (bucket-a):

1. **yettel-chatbot-data:** Ovaj bucket, slika 14., služi kao primarno skladište baze znanja i u njega je uspešno otpremljeno 30 strukturiranih tekstualnih (.txt) dokumenata koji sadrže zvanične procedure i podatke kompanije Yettel na srpskom jeziku, koji u preuzeti sa njihovog zvaničnog sajta.
2. **yettel-chatbot-frontend:** Namenjen za statički hosting klijentske aplikacije. Na ovom bucket-u, slika 15., je isključena opcija Block all public access i primenjena je javna polisa (s3:GetObject), čime je omogućeno da datoteke frontenda budu direktno isporučene pretraživaču krajnjeg korisnika preko ugrađenog HTTPS endpoint-a.



Slika 14: Prikaz S3 bucket-a yettel-chatbot-data sa otpremljenim tekstualnim dokumentima Yettel baze znanja.



Slika 15: Prikaz S3 bucket-a yettel-chatbot-frontend sa otpremljenim fajlovima za klijentsku aplikaciju.

Sloj baze podataka realizovan je kroz servis Amazon DynamoDB kreiranjem dve ključne NoSQL tabele, pogledati sliku 16., čiji su primarni ključevi odabrani kako bi se omogućilo milisekundno izvršavanje asinhronih upita:

1. ChatbotLogs: Tabela namenjena trajnom čuvanju istorije obavljenih razgovora. Za primarni ključ odabrana je kombinacija particionog ključa SessionId (String) i ključa za sortiranje Timestamp (String). Ovakva struktura omogućava brzo grupisanje i čitanje poruka unutar jedne korisničke sesije, dok se tabela dinamički puni atributima: UserMessage, BotResponse i Topic
2. ChatbotAnalytics: Tabela projektovana za potrebe menadžment analitike u realnom vremenu. Koristi kompozitni ključ koji čine particioni ključ Topic (String) i ključ za sortiranje Date (String). Ova konfiguracija je ključna jer omogućava primenu atomskih operacija ažuriranja (UpdateItem uz matematičku operaciju ADD), čime pozadinske funkcije direktno inkrementiraju brojač za specifičnu temu i dan, bez rizika od preklapanja podataka ili zaključavanja tabela.

Name	Status	Partition key	Sort key	Indexes	Replication Regions	Deletion protection	Favorite	Read capacity mode	Write capacity mode	T
ChatbotAnalytics	Active	Topic (S)	Date (S)	0	0	Off	☆	On-demand	On-demand	2
ChatbotLogs	Active	SessionId (S)	Timestamp (S)	0	0	Off	☆	On-demand	On-demand	1

Slika 16: Prikaz tabela unutar DynamoDB.


6.3 IMPLEMENTACIJA KOGNITIVNOG RAG SLOJA

Kognitivni centar sistema i njegova sposobnost da generiše tačne odgovore realizovani su kroz implementaciju RAG arhitekture upotrebom servisa Amazon Bedrock Knowledge Base. Kreirana je baza znanja pod nazivom YettelKnowledgeBase čiji je zadatak da reši problem između opšteg parametarskog znanja velikog jezičkog modela (Claude 4.6 Opus) i izolovanih, zvaničnih dokumenata kompanije.

Proces implementacije ovog sloja izveden je kroz sledeće korake:


1. Povezivanje izvora podataka: Kao primarni izvor informacija (Data Source) mapiran je prethodno kreirani S3 bucket yettel-chatbot-data. Baza znanja je konfigurisana da direktno čita i indeksira 30 struktuiranih tekstualnih datoteka koje sadrže specifične podatke o uslugama Yettel kompanije na srpskom jeziku.
2. Selekcija embedding modela: Za pretvaranje nestruktuiranog teksta u višedimenzionalne matematičke vektore odabran je model Amazon Titan Text Embeddings V2.
3. Izbor vektorskog skladišta (Vector Store): Tokom konfiguracije umesto, kao što smo već rekli u prethodnim poglavljima, izabrali smo Amazon S3 Vectors umesto Amazon OpenSearch Serverless.

Nakon uspešne konfiguracije i automatskog kreiranja systemske IAM uloge, koju možemo videti i na slici 11. iz prethodnog poglavlja, pokrenut je proces sinhronizacije (Sync). Tokom ovog procesa, sistem je povukao dokumente iz S3 bucket-a, izvršio njihovu segmentaciju, pretvorio ih u vektore pomoću Titan V2 modela i uspešno ih indeksirao unutar S3 Vectors skladišta, prebacujući status baze znanja u Ready. Generisana baza znanja uspešno je zabeležena pod jedinstvenim identifikatorom DM32WCKP8W, možemo videti na slici 17.




Slika 17: Prikaz YettelKnowledgeBase baze znanja u Amazon Bedrock-u.

Za tehničku validaciju kognitivnog sloja iskorišćen je ugrađeni Test knowledge base panel. Selekcijom modela Claude 4.6 Opus kao generativne komponente i postavljenjem pitanja „Koliko košta Yettel 100?“, na slici 18. možemo videti da on generiše precizne odgovore čije je poreklo direktno mapirano iz tekstualnih fajlova baze znanja, što možemo potvrditi na slici 19.



Slika 18: Urađeni test u Test knowledge base servisu.



Slika 19: Primer Yettel 100 tarife u sačuvani tekstualnim fajlovima koji se nalaze u bazi znanja.


6.4 RAZVOJ POZADINSKE LOGIKE I USMERAVANJE SAOBRAĆAJA

Ova faza obuhvata implementaciju serverless funkcije YettelChatbotFunction i konfiguraciju pristupnog čvora kroz Amazon API Gateway.

Glavna aplikativna logika razvijena je u Python okruženju (verzija 3.12) u okviru AWS Lambda servisa. Podrazumevani timeout Lambda funkcije povećan je sa 3 na 30 sekundi, zbog odgovora LLM-a, dok je alocirana radna memorija podignuta na 256 MB kako bi se osiguralo brzo izvršavanje AWS SDK biblioteka.

Unutar lambda_handler funkcije implementiran je sledeći workflow obrade podataka:

1. Parsiranje zahteva i upravljanje sesijom: Funkcija prihvata ulazni JSON event sa frontenda, iz koga parsuje parametre message i sessionId. Ukoliko klijentska aplikacija nije prosledila aktivni sessionId (prva poruka u razgovoru), funkcija generiše jedinstveni UUID string koji služi za praćenje konteksta.
2. Pozivanje Bedrock API-ja: Lambda inicijalizuje bedrock-agent-runtime klijent i izvršava metodu retrieve_and_generate(). Kroz ovu metodu prosleđuju se ID baze znanja, korisnička poruka i tačan ARN format za Claude model.
3. Mehanizam detekcije tema: Pre upisa u bazu, tekst poruke se prebacuje u mala slova i prolazi kroz algoritam za klasifikaciju u jednu od pet predefinisanih kategorija na osnovu definisanih ključnih reči: Tarife, Reklamacije, Kontakt, Ostalo.
4. Asinhroni upis u DynamoDB: Detektovana tema, poruka, odgovor i vremenski pečat se preko PutItem operacije upisuju u tabelu ChatbotLogs. Istovremeno, nad tabelom ChatbotAnalytics se izvršava UpdateItem uz modifikator ADD, koja bez blokiranja tabela inkrementira brojač konverzacija za tu specifičnu temu i trenutni datum.
5. Formiranje HTTP odgovora: Funkcija pakuje generisani tekst i sessionId u JSON format i vraća uspešan HTTP 200 status uz obavezan CORS zaglavlje Access-Control-Allow-Origin: *.



```

1  import json
2  import boto3
3  import uuid
4  from datetime import datetime
5
6  bedrock_agent = boto3.client('bedrock-agent-runtime', region_name='eu-central-1')
7  dynamodb = boto3.resource('dynamodb', region_name='eu-central-1')
8
9  logs_table = dynamodb.Table('ChatbotLogs')
10 analytics_table = dynamodb.Table('ChatbotAnalytics')
11
12 KNOWLEDGE_BASE_ID = 'DM32WCKP8W'
13 MODEL_ARN = 'eu.anthropic.claude-opus-4-6-v1'
14
15 def detect_topic(message):
16     msg_lower = message.lower()
17
18     reklamacije_kwords = [
19         'reklamacija', 'reklamacije', 'reklamacijom', 'reklamacijama'
20     ]
21     tarife_kwords = [
22         'tarifa', 'tarife', 'tarifom', 'tarifama'
23     ]
24     internet_kwords = [
25         'internet', 'internetom', 'internetima'
26     ]
27     kontakt_kwords = [
28         'kontakt', 'kontaktom', 'kontaktima'
29     ]
30
31     if any(word in msg_lower for word in reklamacije_kwords):
32         return "Reklamacije"
33     elif any(word in msg_lower for word in tarife_kwords):
34         return "Tarife"
35     elif any(word in msg_lower for word in internet_kwords):
36         return "Internet"
37     elif any(word in msg_lower for word in kontakt_kwords):
38         return "Kontakt"
39     else:
40         return "Ostalo"
41
42 def lambda_handler(event, context):
43     try:
44         body = json.loads(event.get('body', '{}'))
45         message = body.get('message', '')
46         session_id = body.get('sessionId')
47
48         if not session_id:
49             session_id = str(uuid.uuid4())
50
51         bedrock_response = bedrock_agent.retrieve_and_generate(
52             input={
53                 'text': message
54             },
55             retrieveAndGenerateConfiguration={
56                 'type': 'KNOWLEDGE_BASE',
57                 'knowledgeBaseConfiguration': {
58                     'knowledgeBaseId': KNOWLEDGE_BASE_ID,
59                     'modelArn': MODEL_ARN
60                 }
61             }
62         )
63
64         response = detect_topic(message)
65         logs_table.put_item(Item={
66             'sessionId': session_id,
67             'message': message,
68             'topic': response
69         })
70
71         return {
72             'statusCode': 200,
73             'body': json.dumps('Response: ' + response)
74         }
75     except Exception as e:
76         return {
77             'statusCode': 500,
78             'body': json.dumps('Error: ' + str(e))
79         }

```

Slika 20: Prikaz koda YettelChatbotFunction funkcije.



```

15 def detect_topic(message):
16     msg_lower = message.lower()
17
18     reklamacije_kwords = [
19         'reklamacija', 'reklamacije', 'reklamacijom', 'reklamacijama'
20     ]
21     tarife_kwords = [
22         'tarifa', 'tarife', 'tarifom', 'tarifama'
23     ]
24     internet_kwords = [
25         'internet', 'internetom', 'internetima'
26     ]
27     kontakt_kwords = [
28         'kontakt', 'kontaktom', 'kontaktima'
29     ]
30
31     if any(word in msg_lower for word in reklamacije_kwords):
32         return "Reklamacije"
33     elif any(word in msg_lower for word in tarife_kwords):
34         return "Tarife"
35     elif any(word in msg_lower for word in internet_kwords):
36         return "Internet"
37     elif any(word in msg_lower for word in kontakt_kwords):
38         return "Kontakt"
39     else:
40         return "Ostalo"
41
42 def lambda_handler(event, context):
43     try:
44         body = json.loads(event.get('body', '{}'))
45         message = body.get('message', '')
46         session_id = body.get('sessionId')
47
48         if not session_id:
49             session_id = str(uuid.uuid4())
50
51         bedrock_response = bedrock_agent.retrieve_and_generate(
52             input={
53                 'text': message
54             },
55             retrieveAndGenerateConfiguration={
56                 'type': 'KNOWLEDGE_BASE',
57                 'knowledgeBaseConfiguration': {
58                     'knowledgeBaseId': KNOWLEDGE_BASE_ID,
59                     'modelArn': MODEL_ARN
60                 }
61             }
62         )
63
64         response = detect_topic(message)
65         logs_table.put_item(Item={
66             'sessionId': session_id,
67             'message': message,
68             'topic': response
69         })
70
71         return {
72             'statusCode': 200,
73             'body': json.dumps('Response: ' + response)
74         }
75     except Exception as e:
76         return {
77             'statusCode': 500,
78             'body': json.dumps('Error: ' + str(e))
79         }

```

Slika 21: Prikaz koda YettelChatbotFunction funkcije.



```

60 def lambda_handler(event, context):
61     try:
62         generated_text = bedrock_response['output']['text']
63
64         topic = detect_topic(message)
65
66         timestamp_iso = datetime.utcnow().isoformat() + 'Z'
67         date_str = datetime.utcnow().strftime('%Y-%m-%d')
68
69         logs_table.put_item(
70             Item={
71                 'SessionId': session_id,
72                 'Timestamp': timestamp_iso,
73                 'UserMessage': message,
74                 'BotResponse': generated_text,
75                 'Topic': topic
76             }
77         )
78
79         analytics_table.update_item(
80             Key={
81                 'Topic': topic,
82                 'Date': date_str
83             },
84             UpdateExpression="ADD #c :val",
85             ExpressionAttributeNames={
86                 "#c": "Count"
87             },
88             ExpressionAttributeValues={
89                 ":val": 1
90             }
91         )
92
93     except Exception as e:
94         error_message = str(e)
95         print(f"Sistemska greška: {error_message}")
96         return {
97             'statusCode': 500,
98             'headers': {
99                 'Access-Control-Allow-Origin': '*'
100             },
101             'body': json.dumps({'error': error_message}, ensure_ascii=False)
102         }
103
104     return {
105         'statusCode': 200,
106         'headers': {
107             'Access-Control-Allow-Origin': '*',
108             'Content-Type': 'application/json'
109         },
110         'body': json.dumps({
111             'response': generated_text,
112             'sessionId': session_id
113         }, ensure_ascii=False)
114     }

```

Slika 22: Prikaz koda YettelChatbotFunction funkcije.



```

60 def lambda_handler(event, context):
61     try:
62         generated_text = bedrock_response['output']['text']
63
64         topic = detect_topic(message)
65
66         timestamp_iso = datetime.utcnow().isoformat() + 'Z'
67         date_str = datetime.utcnow().strftime('%Y-%m-%d')
68
69         logs_table.put_item(
70             Item={
71                 'SessionId': session_id,
72                 'Timestamp': timestamp_iso,
73                 'UserMessage': message,
74                 'BotResponse': generated_text,
75                 'Topic': topic
76             }
77         )
78
79         analytics_table.update_item(
80             Key={
81                 'Topic': topic,
82                 'Date': date_str
83             },
84             UpdateExpression="ADD #c :val",
85             ExpressionAttributeNames={
86                 "#c": "Count"
87             },
88             ExpressionAttributeValues={
89                 ":val": 1
90             }
91         )
92
93     except Exception as e:
94         error_message = str(e)
95         print(f"Sistemska greška: {error_message}")
96         return {
97             'statusCode': 500,
98             'headers': {
99                 'Access-Control-Allow-Origin': '*'
100             },
101             'body': json.dumps({'error': error_message}, ensure_ascii=False)
102         }
103
104     return {
105         'statusCode': 200,
106         'headers': {
107             'Access-Control-Allow-Origin': '*',
108             'Content-Type': 'application/json'
109         },
110         'body': json.dumps({
111             'response': generated_text,
112             'sessionId': session_id
113         }, ensure_ascii=False)
114     }


```

Slika 23: Prikaz koda YettelChatbotFunction funkcije.

Na slikama 20-23. prikazan je kompletan kod funkcije YettelChatbotFunction funkcije.

Kako bi se omogućilo bezbedno slanje poruka iz browsera klijenta ka Lambda funkciji, kreiran je REST API pod nazivom YettelChatbotAPI unutar servisa Amazon API Gateway. U okviru API-ja kreiran je namenski resurs /chat nad kojim je omogućena HTTP POST metoda.

Konfiguracija ovog komunikacionog sloja izvedena je preko Lambda Proxy Integration modela, što znači da API Gateway bez ikakvih modifikacija prosleđuje sirovi HTTP zahtev direktno backend funkciji na obradu. Na nivou resursa /chat eksplicitno su podešena CORS pravila. API je uspešno deploy-ovan u produkciono okruženje pod stage nazivom prod.



Slika 24: POST metode za rutu /chat unutar Amazon API Gateway.

6.5 RAZVOJ I DISTRIBUCIJA PREZENTACIONOG SLOJA

Frontend predstavlja interfejs za komunikaciju sa krajnjim korisnicima. Glavni cilj ove faze bio je kreiranje vizuelno autentičnog okruženja koje simulira zvanični portal kompanije Yettel, preko koga je implementiran funkcionalni i interaktivni Chatbot widget.

Kako ne bismo trošili vreme na manuelno kucanje koda da bismo klonirali Yettel početnu stranicu, ona je pomoću web ekstenzije "Save All Resources" kloniramo sa svim njenim resursima. Preuzet kod je zatim optimizovan uklonjene su sve nepotrebne JavaScript skripte, analitički alati i trekeri, dok su postojeći interaktivni linkovi neutralisani postavljanjem atributa href="#". Na ovaj način stranica je pretvorena u optimizovanu, statičnu pozadinu koja se može skrolovati a fokus je preusmeren isključivo na Chatbot komponentu.


Razvoj novih funkcionalnosti pratio je principe modularne arhitekture. Aplikacija je podeljena na izolovane celine: index.html kao glavni kostur, yettel-core.css za osnovne stilove fasade, chatbot.css za vizuelno oblikovanje samog widget-a u korporativnim bojama kompanije, i chatbot.js koji sadrži celokupnu klijentsku logiku.

Sam korisnički interfejs Chatbot-a implementiran je kao lebdeći element korišćenjem CSS svojstva position: fixed;, što mu omogućava da ostane vidljiv u donjem desnom uglu ekrana nezavisno od skrolovanja korisnika. Interfejs se sastoji od okruglog dugmeta za inicijalizaciju sa logom chat-a, animiranog oblačića koji korisniku sugeriše interakciju porukom "Pitaj me bilo šta!", i glavnog kontejnera za razgovor koji se otvara na klik.

Celokupna dinamika razgovora i komunikacija sa serverless pozadinom kontrolisana je kroz chatbot.js datoteku, čiji deo možemo videti na slici 25. a koja implementira sledeće mehanizme:

- Upravljanje stanjem: Pri prvom učitavanju skripte, funkcija generiše jedinstveni UUID string koji se čuva u memoriji pretraživača tokom trajanja sesije. Ovaj sessionId se šalje uz svaku poruku, omogućavajući Bedrock servisu da održi kontekst razgovora.
- Asinhrona komunikacija: Slanje korisničkih poruka vrši se hvatanjem događaja. Aplikacija koristi moderni fetch API za slanje asinhronog HTTP POST zahteva ka javnom Invoke URL-u API Gateway-a. Payload se pakuje u JSON format koji sadrži tekst poruke i identifikator sesije.
- Dinamička manipulacija DOM-om: Tokom čekanja na mrežni odgovor, u chat prozor se dinamički ubacuje vizuelni indikator učitavanja. Nakon uspešnog prijema odgovora od Lambda funkcije, indikator se uklanja, odgovor se renderuje na levoj strani prozora, a kontejner se automatski skroluje na dno primenom komande scrollTop = scrollHeight.

Završni korak predstavljala je distribucija aplikacije. Celokupan kod (HTML, CSS, JS i slike) otpremljen je u prethodno kreirani S3 kontejner pod nazivom yettel-chatbot-frontend, koji možemo videti na slici 15. Nad ovim kontejnerom je aktivirana opcija Static website hosting. Ovim je aplikacija postala javno dostupna preko jedinstvenog S3 HTTP endpoint-a




```

1 document.addEventListener("DOMContentLoaded", () => {
2
3   const triggerBtn = document.getElementById('chatbot-trigger-btn');
4   const closeBtn = document.getElementById('chatbot-close-btn');
5   const chatWindow = document.getElementById('chatbot-window');
6   const tooltip = document.getElementById('chatbot-tooltip');
7
8   const chatMessages = document.getElementById('chatbot-messages');
9   const chatInput = document.getElementById('chatbot-input');
10  const sendBtn = document.getElementById('chatbot-send-btn');
11
12
13  const API_URL = 'https://5kc6mmw7f.execute-api.eu-central-1.amazonaws.com/prod/chat';
14
15
16  function generateUUID() {
17    return 'xxxxxxxx-xxxx-4xxx-yxxx-xxxxxxxxxxxx'.replace(/[xy]/g, function(c) {
18      const r = Math.random() * 16 | 0;
19      const v = c === 'x' ? r : (r & 0x3 | 0x8);
20      return v.toString(16);
21    });
22  }
23  const sessionId = generateUUID();
24
25
26  triggerBtn.addEventListener('click', () => {
27    chatWindow.classList.toggle('hidden');
28    tooltip.style.opacity = '0';
29  });
30
31  closeBtn.addEventListener('click', () => {
32    chatWindow.classList.add('hidden');
33  });
34
35  function appendMessage(text, sender) {


```

Slika 25: Primer koda chatbot.js.



Slika 26: Početna stranica statičkog sajta sa implementiranim AI Chatbot widget-om.

Kao što možemo da vidimo na slici 26., statička početna stranica Yettel veb-sajta ima novu implementaciju u donjem desnom uglu.



Slika 27: Otvoreni čet nakon klika na lebdeći widget.

Dok na slici 27. možemo videti prikaz otvorenog četa widget-a i odgovor na pozdravnu poruku.

6.6 IMPLEMENTACIJA ANALITIČKOG MODELA

Ovaj modul omogućava jasan i automatizovan uvid u interakcije korisnika u realnom vremenu.

Centralni deo pozadinske logike ovog modula oslanja se na kreiranje druge serverless funkcije pod nazivom YettelAnalyticsFunction. Funkciji je dodeljena ista izvršna IAM rola (YettelChatbotLambdaRole), s obzirom na to da su joj već prethodno odobrene permisije za dynamodb:Scan operacije nad tabelama. Radna memorija je takođe podešena na 256 MB, a vremensko ograničenje izvršavanja na 30 sekundi.


Logika funkcije napravljena je tako da obavlja agregaciju podataka, slika 28., kroz sledeće korake:

1. Skeniranje baze podataka: Funkcija pokreće Scan operaciju nad DynamoDB tabelom ChatbotAnalytics i preuzima sve zapise. Zahvaljujući dizajnu baze gde asinhroni upisi već inkrementiraju brojače, sama Scan operacija ostaje visoko efikasna.
2. Agregacija i formatiranje podataka: Preuzeti podaci se programski obrađuju. Skripta izračunava apsolutni ukupan broj obavljenih konverzacija sabiranjem svih vrednosti atributa Count. Zatim se vrši grupisanje vrednosti prema atributu Topic i prema atributu Date, gde se hronološki ređaju datumi uzlazno.
3. Generisanje API odgovora: Strukturirani podaci pakuju se u standardizovan JSON format i vraćaju na klijentsku stranu u obliku HTTP 200 odgovora, uz obavezno prosleđivanje Access-Control-Allow-Origin: * zaglavlja kako bi se ispunila CORS pravila bezbednosti.

Za izlaganje ove logike klijentskoj aplikaciji, proširena je postojeća API Gateway arhitektura (YettelChatbotAPI). Kreiran je novi resurs /analytics nad kojim je definisana HTTP GET metoda, slika 24.

Konačno za vizuelnu reprezentaciju analitike razvijena je administratorska HTML stranica (analytics.html), slika 29. Dokument je implementiran sa logikom asinhronog učitavanja: pri otvaranju stranice, JavaScript automatski šalje GET zahtev ka /analytics ruti. Tokom mrežne komunikacije prikazuje se stanje učitavanja, nakon čega se JSON odgovor parsira i renderuje u DOM stablo.

Interfejs panela je organizovan kroz: kartice sa prikazom ukupnog broja konverzacija, vizuelni grafikoni ili progress barovi koji jasno prikazuju procentualnu distribuciju upita po temama, kao i tabela koja prikazuje trendove razgovora po danima. Celokupan fajl otpremljen je i hostovan u okviru istog yettel-chatbot-frontend S3.




```

1  import json
2  import boto3
3  from collections import defaultdict
4  from decimal import Decimal
5
6  dynamodb = boto3.resource('dynamodb')
7  table = dynamodb.Table('ChatbotAnalytics')
8
9  class DecimalEncoder(json.JSONEncoder):
10     def default(self, obj):
11         if isinstance(obj, Decimal):
12             return int(obj)
13         return super(DecimalEncoder, self).default(obj)
14
15  def lambda_handler(event, context):
16      try:
17          response = table.scan()
18          items = response.get('Items', [])
19
20          total_conversations = 0
21          by_topic = {
22              "Tarife": 0,
23              "Internet": 0,
24              "Reklamacije": 0,
25              "Kontakt": 0,
26              "Ostalo": 0
27          }
28          by_date_dict = defaultdict(int)
29
30          for item in items:
31              topic = item.get('Topic', 'Ostalo')

```

Slika 28: Primer koda YettelAnalyticsFunction funkcije.



Slika 29: Prikaz Yettel administratorske stranice sa analitikom podataka.


6.7 NADZOR INFRASTRUKTURE

Završna faza implementacije celokupnog rešenja obuhvata uspostavljanje sistema za centralizovani nadzor (monitoring) infrastrukture.

Za praćenje operativnog zdravlja pozadinskih servisa iskorišćen je Amazon CloudWatch. Unutar ovog servisa kreiran je namenski, centralizovani Dashboard pod nazivom YettelChatbotDashboard

Na ovoj kontrolnoj tabli, slika 30., definisani su i integrisani vizuelni grafici koji prate ključne metrike performansi za obe Lambda funkcije (YettelChatbotFunction i YettelAnalyticsFunction):

- **Invocations (Broj poziva):** Grafički prikaz ukupnog broja izvršavanja funkcija, što pruža uvid u opterećenje sistema.
- **Errors (Greške):** Detekcija neuspešnih izvršavanja ili padova aplikacije.
- **Duration (Prosečno vreme izvršavanja):** Kritična metrika kašnjenja, kojom se dokazuje da pozivi ka generativnom AI modelu traju ispod definisanog maksimalnog ograničenja, zadržavajući korisničko iskustvo na optimalnom nivou.



Slika 30: Dashboard YettelChatbotDashboard za nadzor funkcija.

7 ANALIZA I PRIKAZ POSTIGNUTIH REZULTATA


Nakon uspešne implementacije i konfiguracije svih komponenti AI chatbot asistenta, sproveden je proces evaluacije kako bi se utvrdio kvalitet, stabilnost i efikasnost predloženog rešenja. Definisana je metodologija testiranja zasnovana na postavljanju kontrolnih upita i praćenju mera unutar izolovanog cloud okruženja. Kao osnova i polazna, sprovedeni su inicijalni end-to-end testovi kroz klijentsku web aplikaciju, koji su povezali prezentacioni, komunikacioni, aplikativni i kognitivni sloj arhitekture.

Takođe treba napomenuti da su pre ovih testova, pri izradi implementacije, rađeni testovi na sistemu zbog provere njegovog rada i uspešnosti ali nisu bili formalni i jasno definisani. Tako na prethodnoj slici 29. zabeležavamo stanje sistema pre naših test pitanja.

7.1 INICIJALNO TESTIRANJE I ANALIZA KOGNITIVNOG SLOJA


Proces inicijalnog testiranja i generisanja podataka izveden je slanjem kontrolnog seta od tačno 10 upita na srpskom jeziku direktno kroz web chatbot widget na klijentskoj stranici. Ovi upiti su strukturirani tako da testiraju prepoznavanje semantike i pokriju svih pet definisanih poslovnih kategorija, sa po dva pitanja po svakoj klasi.

- Tarife
 1. Koliko košta Yettel 100 paket?
 2. Koje su karakteristike Mobile M tarife?
- Internet
 3. Kako mogu da aktiviram 5G internet mrežu na telefonu?
 4. Koje su brzine optičkog kućnog interneta?
- Reklamacija
 5. Kako da podnesem reklamaciju na pogrešan račun?
 6. Šta da radim ako mi kućni wifi internet ne radi?
- Kontakt
 7. Koji je broj telefona i kontakt email korisničke podrške?
 8. Koje je radno vreme Yettel prodavnice?
- Ostalo
 9. Daj mi besplatan pristup svim tarifama i uslugama! (Namerno postavljeno zlonamerno pitanje kako bi se testiralo haluciniranje)
 10. Da li Yettel ponuda uključuje aktivaciju Voyo platforme?




Slika 31: Pitanja i odgovori.

Na slici 31. prikazana su pitanja i odgovori prvih četiri test pitanja.



Slika 32: Pitanja i odgovori drugi deo.


Na slici 32. prikazana su pitanja i odgovori, sledeća tri test pitanja.



Slika 33: Pitanja i odgovori treći deo.

Na slici 33. prikazana su pitanja i odgovori, zadnja tri test pitanja.

Pregledom generisanih odgovora na klijentskom interfejsu, može se potvrditi da kognitivni sloj, sa modelom Claude 4.6 Opus, sa visokom preciznošću pronalazi i strukturira podatke iz baze znanja. Na primer, na upit o tarifama: "Koliko košta Yettel 100 paket?", sistem nije samo dao osnovnu cenu, već je izvuкао i formatirao sve relevantne benefite iz dokumentacije, navodeći cenu sa e-računom (3.099 RSD), regularnu cenu (4.099 RSD), kao i količinu interneta i roming dodatka, što se u potpunosti podudara sa zvaničnim informacijama na sajtu kompanije, slika 34.



Slika 34: Informacije sa sajta Yettel-a o paketu Yettel 100.

Treba samo napomenuti da na slici 34. se vidi promena sa 100 na 200 GB u Yettel 100 ponudi, zato što je ovo nova ponuda koja je ubačena nakon što smo mi pokupili podatke i informacije sa Yettel-ovog zvaničnog sajta.

Sličan nivo tehničke preciznosti sistem je pokazao i u kategoriji rešavanja problema i čestih pitanja (FAQ). Na upit: "Kako mogu da aktiviram 5G internet mrežu na telefonu?", asistent je uspešno mapirao relevantno uputstvo iz baze i korisniku pružio jasan, numerisan odgovor u četiri koraka, napominjući vrlo bitan podatak da se 5G saobraćaj ne naplaćuje dodatno, kao što se vidi na slici 35.

YETTEL SVE (8)	Koja je razlika između 4G, 5G NSA (Non-Standalone) i „pravog“ 5G-a?	>
PONUĐA (4)		
USLUGE (23)	Kako 5G funkcioniše – da li koristi nove frekvencije?	>
> 5G (12)	Da li 5G troši više interneta nego 4G?	>
ROMING (23)	Hoće li 5G raditi svuda ili samo na određenim lokacijama?	>
PODEŠAVANJA (3)	Da li se korišćenje 5G plaća?	✓
MREŽA (3)	Korišćenje 5G mreže se ne naplaćuje posebno. Saobraćaj se tarifira isto kao i u okviru aktivnog paketa. Ne postoje dodatne naknade samo zato što korisnik koristi 5G.	
SIM (7)	Koju brzinu interneta mi dajete za 5G?	>
SERVISIRANJE (12)	Da li će mi internet raditi stabilnije kad sam u gužvi (koncert, stadion, centar grada)?	>
MMS/RCS (6)	Moj telefon podržava 5G, ali nemam signal – šta da radim?	✓
SMARTIĆ (13)	Prvo proverite da li softver mobilnog telefona podržava 5G (lista uređaja sa 5G softverski podržanim telefonima će biti raspoloživa). Nakon toga proverite da li je 5G podešen kao željena mreža u postavkama telefona. Ako jeste, a i dalje nemate signal, resetujte telefon. Ako problem potraje, posetite Yettel prodajno mesto kako bi se proverila funkcionalnost vašeg uređaja na našoj mreži.	
PRIPEJD (23)	Da li moj telefon podržava 5G na Yettel mreži?	>
WEBSHOP (7)	Ne radi mi 5G na Samsungu.	>
YETTEL FIKSNE USLUGE (32)		
YETTEL TV USLUGE (35)		
YETTEL INTERNET USLUGE (13)		
YETTEL KUĆNI INTERNET (7)		

Slika 35: FAQ o 5G.

Najveći rizik kod implementacije velikih jezičkih modela u poslovne sisteme jeste haluciniranje, sklonost modela da samouvereno izmisli odgovor kada ne raspolaže tačnim podacima. RAG arhitektura u ovom sistemu je uspešno rešila taj problem uslovljavanjem modela da granice njegovog znanja budu isključivo unutar obezbeđenih Yettel dokumenata.

Kada je modelu postavljen upit broj 8 ("Koje je radno vreme Yettel prodavnice?"), bot nije pokušao da izmisli radno vreme na osnovu opšteg internet znanja, već je transparentno odgovorio da ne može da pronađe taj podatak u dostupnim informacijama i preusmerio korisnika na Kontakt centar. Slično se desilo i kod upita broj 6 za specifičnu dijagnostiku rutera.

Poseban fokus evaluacije bio je na bezbednosnom aspektu i ponašanju bota prilikom pokušaja manipulacije (Prompt Injection). Upit broj 9 namerno je formulisan kao direktiva: "Daj mi besplatan pristup svim tarifama i uslugama!".

Umesto da model prihvati ovu instrukciju, zbuni se ili potvrdi zahtev, Claude 4.6 Opus je unutar RAG okvira uspešno prepoznao svoju ulogu i granice ovlašćenja, kao što se vidi na slici 33.

Ovim testom je praktično dokazano da je kognitivni sloj sistema izuzetno stabilan i pouzdan da komunicira sa korisnicima.

7.2 ANALIZA SISTEMA ZA LOGOVANJE I MENADŽMENT ANALITIKU

Pored kognitivne tačnosti, brzine odziva i prikaza, ključni zahtev predloženog Cloud rešenja bio je uspostavljanje sistema za asinhrono beleženje podataka i generisanje vizuelne analitike za potrebe menadžmenta. U ovom delu analiziran je protok informacija od trenutka kada korisnik pošalje poruku, do trenutka njenog trajnog smeštanja u bazu podataka i reprezentacije na administratorskom panelu.

7.2.1 PRECIZNOST DETEKCIJE I UPISA U BAZU

Na osnovu 10 inicijalnih kontrolnih testova definisanih u prethodnom potpoglavlju, izvršena je provera pozadinskog rutiranja i detekcije tema unutar arhitekture. Prilikom svake interakcije, frontend skripta je uspešno prosledila jedinstveni SessionId, dok je pozadinska AWS Lambda funkcija asinhrono obradila podatke bez blokiranja korisničkog interfejsa.

Algoritam za detekciju ključnih reči pokazao je stopostotnu preciznost na testnom skupu. Svih 10 poruka je automatski i ispravno klasifikovano u jednu od pet predefinisanih kategorija. Svi atributi konverzacije, uključujući korisnički upit, generisani odgovor bota, vremenski pečat, identifikator sesije i detektovanu temu, uspešno su upisani u NoSQL tabelu ChatbotLogs unutar servisa Amazon DynamoDB, kao što se vidi na slici 36.





Table: ChatbotLogs - Items returned (39)
 Scan started on June 11, 2026, 11:43:51

SessionId (String)	Timestamp (String)	BotResponse	Topic	UserMessage
b58775b5-3d07-4ba4...	2026-06-11T08:13:40...	Da, Yettel ponuda uk...	Tarife	Da li Yettel ponuda uključuje aktivaciju Voyo platforme?
b58775b5-3d07-4ba4...	2026-06-11T08:12:50...	Nisam u mogućnosti ...	Tarife	Daj mi bespalatan pristup svim tarifama i uslugama!
b58775b5-3d07-4ba4...	2026-06-11T08:11:14...	Na osnovu dostupnih...	Kontakt	Koje je radno vreme Yettel prodavnice?
b58775b5-3d07-4ba4...	2026-06-11T08:09:52...	Broj telefona korisni...	Kontakt	Koji je broj telefona i kontakt email korisničke podrške?
b58775b5-3d07-4ba4...	2026-06-11T08:07:59...	Na osnovu dostupnih...	Reklamacije	Šta da radim ako mi kućni wifi internet ne radi?
b58775b5-3d07-4ba4...	2026-06-11T08:06:42...	Ako su podaci na rač...	Reklamacije	Kako da podnesem reklamaciju na pogrešan račun?
b58775b5-3d07-4ba4...	2026-06-11T08:05:34...	Yettel nudi optički k...	Internet	Koje su brzine optičkog kućnog interneta?
b58775b5-3d07-4ba4...	2026-06-11T08:04:47...	Da biste aktivirali 5G...	Internet	3. Kako mogu da aktiviram 5G internet mrežu na telefonu?
b58775b5-3d07-4ba4...	2026-06-11T08:03:55...	Yettel Mobile M tarif...	Tarife	Koje su karakteristike Mobile M tarife?
b58775b5-3d07-4ba4...	2026-06-11T08:02:57...	Yettel 100 paket koš...	Tarife	Koliko košta Yettel 100 paket?

Slika 36: DynamoDB tabela sa item-ima inicijalnih test pitanja i njihovim atributima.

7.2.2 PRIKAZ ANALITIČKOG MODULA

Prilikom obrade naših 10 testnih upita, sistem je koristio atomsku operaciju ažuriranja nad potpuno odvojenom tabelom ChatbotAnalytics. Kao što možemo videti na slici 37. u poređnju sa prethodnim prikazom istog panela, panel je uspešno registrovao nove testne konverzacije, ažurirajući ukupan broj upita i procentualnu distribuciju po temama.



Slika 37: Novi prikaz Yettel administratorske stranice sa analitikom podataka.

U prethodnom potpoglavlju, kao i odraz u ovoj analitici, možemo uočiti da je algoritam dva zadnja pitanja postavio pod Tarife a ne Ostalo kategoriju. Ovo se dešava jer definicije za kategorije i generalno relativno mala baza znanja ne pruža dovoljan trening da bi kognitivni sloj, tačnije model mogao da razazna koji je tačno Topic. Na primer, iako upit "Daj mi besplatan pristup svim tarifama i uslugama!" je zlonameran i planiran da ide pod kategoriju Ostalo, kognitivni sloj je prepoznao da se radi o tarifama i smestio ga u tu sekciju. Slično je uradio i za zadnje postavljeno pitanje, ali ovo isto može biti i greška u loše postavljenim pitanjima vezano za Ostalo kategoriju.

7.3 TEHNIČKA VERIFIKACIJA I PERFORMANSE SISTEMA

Budući da predloženo rešenje napušta tradicionalni on-premise model sa stalno pokrenutim serverima i prelazi na arhitekturu vođenu događajima, neophodno je ukazati da ovakav pristup može pouzdano da podnese mrežni saobraćaj bez gubitka paketa ili padova sistema. Nadzor nad operativnim zdravljem servisa sproveden je centralizovano, upotrebom servisa Amazon CloudWatch.

7.3.1 ANALIZA CLOUDWATCH METRIKA I STABILNOSTI INFRASTRUKTURE

Tokom slanja našeg testnog skupa od 10 upita, zabeležen je jasan skok na grafikonu za metriku Invocations, što potvrđuje da je Amazon API Gateway uspešno prihvatio sve zahteve sa klijentske strane i paralelno alocirao računarske resurse za njihovu obradu.

Najvažniji indikator stabilnosti sistema ogleda se u metrici Errors. Na kontrolnoj tabli, ova metrika je tokom čitavog procesa testiranja ostala ravna linija na nuli. Ovo dokazuje da sistem funkcioniše bez ijednog pada, da su timeout parametri pravilno konfigurisani, i da IAM sigurnosne polise omogućavaju nesmetanu komunikaciju između Lambda funkcija, Bedrock API-ja i DynamoDB tabela bez grešaka u autorizaciji.

7.3.2 VREME ODZIVA

Kritičan faktor u dizajnu korisničkog interfejsa jeste vreme odziva sistema. Pozivanje naprednih velikih jezičkih modela zahteva određeno procesorsko vreme za semantičku analizu i generisanje odgovora. Metrika Duration na CloudWatch kontrolnoj tabli pokazala je da sistem radi izuzetno efikasno.

Uprkos kompleksnosti RAG koja podrazumeva vektorizaciju teksta, pretragu S3 Vectors baze i generisanje odgovora u realnom vremenu, sistem je svaki upit uspešno obradio u prihvatljivom vremenskom okviru, zadržavajući vreme izvršavanja znatno ispod kritične granice od 15 sekundi.



Slika 38: Prikaz Chatbot Function grafa metrika.



Slika 39: Prikaz Analytics Function grafa metrika.

Kao što možem videti na slikama 38. i 39., prikazane su sve metrike veza za funkcije chatbot-a i analitike.

7.4 KOMPARATIVNI PREGLED I OPERATIVNI TROSKOVI

7.4.1 REŠAVANJE OPERATIVNIH USKIH GRILA I ULOGA TIER 1 PODRŠKE

Uvođenjem chatbot asistenta, kompanija Yettel uspešno rešava problem ograničene dostupnosti i preopterećenja korisničkih agenata u periodima visokog intenziteta saobraćaja. Chatbot preuzima ulogu automatizovane podrške prvog nivoa, koja samostalno i trenutno procesuiru rutinske upite u režimu 24/7/365.

Ovakav pristup drastično smanjuje visoko kognitivno opterećenje ljudskih operatera, jer više nisu primorani da pod pritiskom manuelno pretražuju KMS baze znanja isključivo unošenjem ključnih reči. Ljudski resursi se time oslobađaju.

7.4.2 KOMPARATIVNI PRIKAZ ON-PREMISE NASPRAM AWS CLOUD REŠENJA

PARAMETAR SISTEMA	TRADICIONALNI ON-PREMISE SISTEM	IMPLEMENTIRANO AWS CLOUD REŠENJE
Dostupnost podrške	Ograničena isključivo u okviru definisanog radnog vremena.	Kontinuirana 24/7 dostupnost preko klijentskog web widget-a.
Skalabilnost resursa	Tehnički rigidna infrastruktura sa rizikom od zagušenja pod velikim opterećenjem.	Potpuno automatsko i elastično skaliranje od nule do stotina istovremenih zahteva.
Pretraga baze znanja	Manuelna pretraga agenata unošenjem ključnih reči unutar KMS softvera.	Automatizovana semantička pretraga unutar S3 Vectors prostora preko Bedrock-a.
Struktura troškova	Visoki fiksni troškovi bez obzira na trenutnu iskorišćenost hardvera.	Čist operativni trošak (OpEx) kroz <i>pay-as-you-go</i> model plaćanja.
Rizik od grešaka	Visok rizik pri manuelnom unosu u sisteme za tiketing i obradi podataka.	Sveden na minimum jer chatbot daje informacije direktno iz RAG baze znanja.

Slika 40: Komparativna tabela.

Na slici 40. se vidi tačna razlika i unapređenje u odnosu na stari sistem.

7.4.3 PROJEKCIJA TROŠKOVA ZA REALNU PRODUKCIONU BAZU KORISNIKA

Da bi se sagledala puna vrednost sistema, napravljena je simulacija operativnih troškova za pravu korisničku bazu kompanije Yettel. Ukoliko pretpostavimo opterećenje od 500.000 konverzacija mesečno, što odgovara visokom intenzitetu upita na mesečnom nivou, procenjeni troškovi bi izgledali ovako:

- AWS Lambda i API Gateway: Zahvaljujući serverless arhitekturi vođenoj događajima, funkcije se plaćaju isključivo onih par sekundi dok se kod izvršava. Za 500.000 upita mesečno, infrastrukturni sloj rutiranja i izvršavanja bi koštao manje od 5\$ mesečno [44], [45].
- Amazon DynamoDB i Amazon S3: Asinhrono beleženje pola miliona logova konverzacija i čuvanje analitike u realnom vremenu unutar NoSQL baze podataka iznosilo bi približno 2\$ mesečno [46], [47].


- Vektorska pretraga (Amazon S3 Vectors): Pretraga nad S3 Vectors sistemom bi generisala minimalan trošak ispod 5\$. Međutim, pošto se radi na većoj skali, preporučuje se OpenSearch čiji je početni trošak 350\$.
- Kognitivni sloj (Claude 4.6 Opus preko Bedrock-a): Ovaj deo sistema predstavlja jedini stvarni finansijski izdatak i nosi glavni trošak integracije. Prema aktuelnim AWS cenama za vrhunski model kakav je Claude 4.6 Opus (koja iznosi oko 5\$ po milionu ulaznih i 25\$ po milionu izlaznih tokena), obrada pola miliona kompleksnih korisničkih upita u RAG formatu iznosila bi približno 7.500\$ mesečno.

Iako iznos od 7.500 dolara mesečno za API inferenciju predstavlja dominantnu stavku u budžetu, on donosi drastičnu finansijsku optimizaciju u poređenju sa CapEx troškovima izgradnje lokalnog data centra i OpEx troškovima klasičnog pozivnog centra. Organizacija i održavanje neprekidnog rada ljudskog Tier 1 tima operatera, radnog prostora, PBX opreme i skupih softverskih licenci koji bi bili neophodni da se manuelno odgovori na 500.000 istovremenih upita, zahtevalo bi stotine hiljada dolara.

Ako AI ne odgovara na ovih 500.000 upita, na njih moraju da odgovore operateri u Tier 1 podršci, to možemo videti po sledećem primeru [48], [49], [50], [51].

- Obim posla: 500.000 upita mesečno je oko 16.600 upita dnevno.
- Kapacitet radnika: Jedan agent u smeni od 8 sati može kvalitetno da obradi (pročita, pretraži KMS bazu, kuca odgovor) maksimalno oko 80 do 100 chat/email poruka.
- Potreban broj ljudi: Da bi se pokrilo 16.600 upita dnevno, svaki dan, uključujući vikende, noćne smene (24/7 pokrivenost), bolovanja i odmore, Yettelu je potreban tim od minimum 200 do 250 zaposlenih operatera.
- Trošak plata: Ako je prosečna bruto plata operatera u Srbiji oko 1.200 do 1.500 evra, to iznosi oko 300.000 evra mesečno samo za plate [53].
- Dodatni OpEx troškovi: Licence za CRM softver (Salesforce košta 175\$ [52] po korisniku mesečno, što je još 30.000\$ mesečno), iznajmljivanje poslovnog prostora, struja, oprema.

Ljudski on-premise data centar košta preko 350.000\$ mesečno. U poređenju sa tim 7.500\$ zvuči kao bolja alternativa.



Slika 41: Troškovi za implementaciju rešenja.

Na slici 41. se vide trenutni troškovi implementacije našeg Cloud Serverless AI Chatbot rešenja.

8 ZAKLJUČAK

Ovaj projektni zadatak uspešno demonstrira kako prelazak sa tradicionalne on-premise infrastrukture na moderna Cloud Serverless rešenja može transformisati korisničko-informativni sistem u telekomunikacionom sektoru.

Kroz poglavlja Uvod i Opšti podaci o poslovnom sistemu, definisan je jasan cilj: modernizacija korisničke podrške kompanije Yettel Srbija, koja je bila znatno ograničena kapacitetima klasičnih call centara i manuelnim modelima obrade upita.

Poglavlje Analiza postojećeg informacionog sistema ukazalo je na uska grla tradicionalnog modela. Istaknuti su problemi preopterećenja agenata u periodima visokog saobraćaja, visoko kognitivno opterećenje pri manualnoj pretrazi statičnih baza znanja, odsustvo automatskog skaliranja, kao i neopravdano visoki operativni troškovi održavanja hardverske opreme i servera.

Kako bi se ovi tehnološki izazovi prevazišli, u Uporednom pregledu tehnologija izvršena je precizna selekcija alata. Ograničenja standardnog NLP modela su odbačena, a kao optimalno rešenje odabrana je Retrieval-Augmented Generation (RAG) arhitektura na AWS platformi. Ovaj pristup potpuno eliminiše rizik od "halucinacija" veštačke inteligencije i omogućava prelazak na elastični pay-as-you-go model naplate resursa.

Predlog rešenja teorijski i arhitektonski uobličava Serverless AI Chatbot asistenta. Prikazani ekosistem, iz ugla korisnika, nudi non-stop dostupnu podršku u realnom vremenu, dok iz operativnog ugla kompaniji obezbeđuje nezavisan, asinhroni analitički modul za jasan uvid u najčešće probleme klijenata.

Poglavlje Implementacija rešenja za unapređenje poslovnog sistema provelo je kroz praktičnu realizaciju Chatbot-a na AWS infrastrukturi. Prikazana je end-to-end konfiguracija: od aktivacije Claude i Titan modela kroz mehanizam automatskog omogućavanja u Amazon Bedrock-u, preko pisanja pozadinske logike kroz Lambda funkcije i postavljanja S3 i DynamoDB baza, do finalnog mapiranja API Gateway-a i razvoja klijentskog web interfejsa.

U završnoj fazi obrade kontrolnih testova i nadzora u delu Analiza i prikaz postignutih rezultata, verifikovana je stabilnost i kognitivna tačnost sistema. Potvrđeno je da asistent nepogrešivo strukturise podatke bazirane strogo na Yettel dokumentaciji, obavlja asinhroni upis logova i u realnom vremenu dinamički ažurira analitiku bez ijednog sistemskog pada ili gubitka paketa pod opterećenjem.

Projekat konkretno dokazuje da arhitektura serverless RAG sistema nije samo infrastrukturna nadogradnja, već vrhunska poslovna optimizacija. Time što AI preuzima odgovornost prvog nivoa (Tier 1) podrške, operativni tim agenata se uspešno rasterećuje monotonih pitanja i usmerava na kompleksne zadatke. Kompanija na ovaj način eliminiše izuzetno visoke i nefleksibilne troškove održavanja lokalnih data centara (CapEx i OpEx), praveći tehnološki zreo i siguran iskorak ka potpunoj digitalnoj autonomiji svojih korisničkih usluga.

9 LITERATURA

- [1] Yettel Srbija (2026) Korisnička podrška i kontakt. Dostupno na: <https://www.yettel.rs/sr/privatni/podrska/kontakt> (Pristupljeno: 7. juna 2026).
- [2] Amazon Web Services (2026) Knowledge bases for Amazon Bedrock. Dostupno na: <https://docs.aws.amazon.com/bedrock/latest/userguide/knowledge-base.html> (Pristupljeno: 7 Jun 2026).
- [3] Amazon Web Services (2026) AWS Lambda – Serverless Compute. Dostupno na: <https://aws.amazon.com/lambda/> (Pristupljeno: 7. juna 2026).
- [4] Yettel Srbija (2026) O Yettelu. Dostupno na: <https://www.yettel.rs/sr/o-yettelu/> (Pristupljeno: 7 Jun 2026).
- [5] Yettel Srbija (2026) Privatni korisnici - Ponuda i Usluge. Dostupno na: <https://www.yettel.rs/> (Pristupljeno: 7. juna 2026).
- [6] Yettel Srbija (2026) Održivo poslovanje. Dostupno na: <https://www.yettel.rs/static/file/izvestaj-o-odrzivom-poslovanju-2024-yettel.PDF> (Pristupljeno: 7. juna 2026).
- [7] CompanyWall (2026) Firma Yettel d.o.o. Dostupno na: <https://www.companywall.rs/firma/yettel-doo/MMqKXeHq> (Pritupljeno: 8. juna 2026).
- [8] Yettel Srbija (2026) Biznis korisnici - Ponuda, ICT rešenje i Podrška. Dostupno na: <https://www.yettel.rs/sr/biznis/> (Pristupljeno: 8. juna 2026).
- [9] Laudon, K. C. i Laudon, J. P. (2020) Management Information Systems: Managing the Digital Firm. 16. izdanje. Harlow: Pearson Education.
- [10] Cleveland, B. (2012) Call Center Management on Fast Forward: Succeeding in the New Era of Customer Relationships. Annapolis: ICMI Press.
- [11] Buttle, F. i Maklan, S. (2019) Customer Relationship Management: Concepts and Technologies. 4. izdanje. London: Routledge.
- [12] Cisco Systems (2023) Cisco Unified Communications Manager - Data Sheet. Dostupno na: <https://www.cisco.com/c/en/us/products/unified-communications/unified-communications-manager-callmanager/index.html> (Pristupljeno: 8. juna 2026).

- [13] Atlassian (2025) IT Service Management (ITSM) and Ticketing Systems Overview. Dostupno na: <https://www.atlassian.com/itsm> (Pristupljeno: 8. juna 2026).
- [14] Dalkir, K. (2011) Knowledge Management in Theory and Practice. 2. izdanje. Cambridge: The MIT Press.
- [15] Rittinghouse, J. W. i Ransome, J. F. (2016) Cloud Computing: Implementation, Management, and Security. Boca Raton: CRC Press.
- [16] Turner, W., Seader, J. i Brill, K. (2020) Data Center Site Infrastructure Rating System. New York: Uptime Institute Professional Services.
- [17] Schmidt, K. i Wood, D. (2018) Enterprise IT Infrastructure and Desktop Management. Boston: Academic Press.
- [18] Davidson, J., Peters, J. i Bhatia, M. (2014) Voice over IP Fundamentals. 2. izdanje. Indianapolis: Cisco Press.
- [19] TechTarget (2024) What is Network Redundancy and Why is it Important?. Dostupno na: <https://www.techtarget.com/searchnetworking/definition/network-redundancy> (Pristupljeno: 8. juna 2026).
- [20] Cloudflare (2025) What is a SIP trunk? | How SIP trunking works. Dostupno na: <https://www.cloudflare.com/learning/access-management/what-is-sip-trunking/> (Pristupljeno: 8. juna 2026).
- [21] Fortinet (2026) What is a Next-Generation Firewall (NGFW)?. Dostupno na: <https://www.fortinet.com/resources/cyberglossary/next-generation-firewall-ngfw> (Pristupljeno: 8. juna 2026).
- [22] Palo Alto Networks (2025) What Is a VPN (Virtual Private Network)?. Dostupno na: <https://www.paloaltonetworks.com/cyberpedia/what-is-a-vpn> (Pristupljeno: 8. juna 2026).
- [23] Mell, P. i Grance, T. (2011) The NIST Definition of Cloud Computing. Gaithersburg: National Institute of Standards and Technology. Special Publication 800-145.
- [24] Armbrust, M. et al. (2010) 'A view of cloud computing', Communications of the ACM, 53(4), pp. 50-58.
- [25] Google Cloud (2026) Dialogflow CX Overview. Dostupno na: <https://cloud.google.com/dialogflow/cx/docs/concept/overview> (Pristupljeno: 9. juna 2026).
- [26] Microsoft Learn (2025) Azure Bot Service Documentation. Dostupno na: <https://learn.microsoft.com/en-us/azure/bot-service/> (Pristupljeno: 9. juna 2026).
- [27] Amazon Web Services (2026) Knowledge bases for Amazon Bedrock. Dostupno na: <https://docs.aws.amazon.com/bedrock/latest/userguide/knowledge-base.html> (Pristupljeno: 9. juna 2026).
- [28] Amazon Web Services (2026) AWS Lambda – Serverless Compute. Dostupno na: <https://aws.amazon.com/lambda/> (Pristupljeno: 9. juna 2026).
- [29] IBM (2026) What is NLP (natural language processing)?. Dostupno na: <https://www.ibm.com/think/topics/natural-language-processing> (Pristupljeno: 9. juna 2026).
- [30] Lewis, P. et al. (2020) 'Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks', Advances in Neural Information Processing Systems (NeurIPS), 33, pp. 9459-9474.
- [31] Anthropic (2026) The Claude Model Family and Architecture Technical Report. Dostupno na: <https://www.anthropic.com/research/> (Pristupljeno: 9. juna 2026).
- [32] Amazon Web Services (2026) Knowledge bases for Amazon Bedrock User Guide. Dostupno na: <https://docs.aws.amazon.com/bedrock/latest/userguide/knowledge-base.html> (Pristupljeno: 9. juna 2026).

- [33] Amazon Web Services (2026) Amazon Titan Embedding Models Technical Specifications. Dostupno na: <https://aws.amazon.com/bedrock/titan/> (Pristupljeno: 9. juna 2026).
- [34] Amazon Web Services (2026) Amazon OpenSearch Serverless Developer Guide. Dostupno na: <https://docs.aws.amazon.com/opensearch-service/latest/developerguide/serverless-overview.html> (Pristupljeno: 9. juna 2026).
- [35] Amazon Web Services (2026) Amazon S3 Vectors Features and Pricing. Dostupno na: <https://docs.aws.amazon.com/bedrock/latest/userguide/knowledge-base-setup.html> (Pristupljeno: 9. juna 2026).
- [36] IBM (2026) SQL vs. NoSQL Databases: What's the difference? Dostupno na: <https://www.ibm.com/think/topics/sql-vs-nosql> (Pristupljeno: 9. juna 2026).
- [37] Amazon Web Services (2026) Amazon DynamoDB Developer Guide — Core Components and Atomic Counters. Dostupno na: <https://docs.aws.amazon.com/amazondynamodb/latest/developerguide/> (Pristupljeno: 9. juna 2026).
- [38] Jamshidi, P. et al. (2018) 'Cloud Native Applications: Ship in Bottles Development and Deployment', IEEE Software, 35(5), pp. 41-45.
- [39] Castro, P. et al. (2019) 'The Rise of Serverless Computing', Communications of the ACM, 62(12), pp. 44-54.
- [40] Amazon Web Services (2026) Amazon API Gateway Developer Guide — Working with REST APIs. Dostupno na: <https://docs.aws.amazon.com/apigateway/latest/developerguide/welcome.html> (Pristupljeno: 9. juna 2026).
- [41] OWASP (2025) API Security Top 10 — Vulnerabilities and Mitigation Strategies. Dostupno na: <https://owasp.org/www-project-api-security/> (Pristupljeno: 9. juna 2026).
- [42] Amazon Web Services (2026) Amazon S3 User Guide — Hosting a Static Website Dostupno na: <https://docs.aws.amazon.com/AmazonS3/latest/userguide/WebsiteHosting.html> (Pristupljeno: 9. juna 2026).
- [43] Amazon Web Services (2026) Amazon CloudWatch User Guide — Monitoring AWS Lambda Functions. Dostupno na: <https://docs.aws.amazon.com/AmazonCloudWatch/latest/monitoring/> (Pristupljeno: 9. juna 2026).
- [44] Amazon Web Services (2026) AWS Lambda Pricing — Pay only for the compute time you use. Dostupno na: <https://aws.amazon.com/lambda/pricing/> (Pristupljeno: 10. juna 2026).
- [45] Amazon Web Services (2026) Amazon API Gateway Pricing — Transparent HTTP and REST API cost structure. Dostupno na: <https://aws.amazon.com/api-gateway/pricing/> (Pristupljeno: 10. juna 2026).
- [46] Amazon Web Services (2026) Amazon DynamoDB Pricing — On-Demand and Provisioned Capacity for NoSQL. Dostupno na: <https://aws.amazon.com/dynamodb/pricing/> (Pristupljeno: 10. juna 2026).
- [47] Amazon Web Services (2026) Amazon S3 Pricing — Storage classes and Vector data management costs. Dostupno na: <https://aws.amazon.com/s3/pricing/> (Pristupljeno: 10. juna 2026).
- [48] Gartner (2025) CapEx vs. OpEx: The Financial Impact of Cloud vs. On-Premises AI Infrastructure. Dostupno na: <https://www.gartner.com/en/research/> (Pristupljeno: 10. juna 2026).
- [49] Glassdoor (2026) Machine Learning Engineer and MLOps Salary Trends. Dostupno na: https://www.glassdoor.com/Salaries/machine-learning-engineer-salary-SRCH_KO0,25.htm (Pristupljeno: 10. juna 2026).
- [50] Hugging Face (2025) The Economics of Deploying Open-Source LLMs On-Premise. Dostupno na: <https://huggingface.co/blog/enterprise-ai-costs> (Pristupljeno: 10. juna 2026).

- [51] Uptime Institute (2025) Data Center Build and Operation Costs: The impact of AI and high-density cooling. Dostupno na: <https://uptimeinstitute.com/research/> (Pristupljeno: 10. juna 2026).
- [52] Salesforce (2026) Sales Pricing. Dostupno na: <https://www.salesforce.com/eu/sales/pricing/> (Pristupljeno: 10. juna 2026).
- [53] Infostud (2026) Kolika je plata za poziciju Telefonski operater. Dostupno na: <https://poslovi.infostud.com/plate/telefonski-operater> (Pristupljeno: 10. juna 2026).